

TRƯỜNG ĐẠI HỌC AN GIANG
KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP NGÀNH KỸ THUẬT PHẦN MỀM

HUẤN LUYỆN TÁC NHÂN HỌC TĂNG
CƯỜNG SÂU TRONG MÔI TRƯỜNG MÔ
PHỎNG GIAO DỊCH TÀI SẢN SỐ

HUỲNH NHỰT PHÁT

AN GIANG, 04-2026

TRƯỜNG ĐẠI HỌC AN GIANG
KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP NGÀNH KỸ THUẬT PHẦN MỀM

HUẤN LUYỆN TÁC NHÂN HỌC TĂNG
CƯỜNG SÂU TRONG MÔI TRƯỜNG MÔ
PHỎNG GIAO DỊCH TÀI SẢN SỐ

HUỲNH NHỰT PHÁT
DPM225455

HỌ TÊN GIẢNG VIÊN HƯỚNG DẪN: TS. HUỲNH PHƯỚC HẢI

AN GIANG, 04-2026

Khoá luận “Huấn luyện tác nhân học tăng cường sâu trong môi trường mô phỏng giao dịch tài sản số” do sinh viên Huỳnh Nhựt Phát thực hiện dưới sự hướng dẫn của TS. Huỳnh Phước Hải. Tác giả đã báo cáo kết quả nghiên cứu và được Hội đồng Khoa học và Đào tạo thông qua ngày 06 tháng 05 năm 2026.

Phản biện 1

(Ký và ghi rõ chức danh, họ tên)

Phản biện 2

(Ký và ghi rõ chức danh, họ tên)

Giảng viên hướng dẫn

(Ký và ghi rõ chức danh, họ tên)

LỜI CẢM ƠN

Để hoàn thành khóa luận này, bên cạnh sự nỗ lực của bản thân, em đã nhận được sự giúp đỡ vô cùng quý báu từ quý thầy cô, gia đình, bạn bè và nhà trường. Bên cạnh đó, em còn được truyền cảm hứng sâu sắc từ các công trình nghiên cứu đi trước. Em xin được bày tỏ lòng biết ơn chân thành nhất đến với tất cả mọi người.

Trước tiên, em xin gửi lời cảm ơn sâu sắc đến Ban Giám hiệu Trường Đại học An Giang cùng toàn thể quý thầy cô Khoa Công Nghệ Thông Tin đã tạo điều kiện học tập tốt nhất, trang bị cho em những kiến thức nền tảng vững chắc trong suốt những năm tháng ngồi trên giảng đường.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc nhất đến TS. Huỳnh Phước Hải. Thầy đã dành nhiều thời gian quý báu, tận tâm định hướng khoa học, cũng như tận tình hướng dẫn và truyền đạt kiến thức cho em. Thầy không chỉ tạo điều kiện giúp em hoàn thiện khóa luận mà còn rèn luyện cho em những kỹ năng nghiên cứu vô cùng giá trị.

Em cũng xin trân trọng cảm ơn các thầy cô trong Hội đồng đánh giá đã dành thời gian đọc, nhận xét và đóng góp những ý kiến phản biện quý báu, giúp em nhìn nhận vấn đề đa chiều hơn và hoàn thiện đề tài ở mức tốt nhất có thể.

Em xin gửi lời tri ân sâu sắc đến gia đình đã luôn động viên tinh thần và tạo điều kiện tốt nhất cho em. Em cũng xin cảm ơn những người bạn, đồng nghiệp đã luôn đồng hành, chia sẻ kiến thức và hỗ trợ em.

Cuối cùng, em xin gửi lời tri ân đến các chuyên gia, nhà khoa học đã công bố những công trình nghiên cứu giá trị. Những tài liệu đó là nền tảng quan trọng giúp em củng cố kiến thức và xây dựng khung lý thuyết vững chắc cho đề tài. Đặc biệt, em xin trân trọng cảm ơn những đóng góp to lớn của tác giả Richard S. Sutton và Andrew G. Barto; nguồn tài liệu tham khảo từ các ông đã giúp em thấu hiểu sâu sắc bản chất của bài toán học tăng cường.

Mặc dù đã nỗ lực hết mình, nhưng do những hạn chế về mặt thời gian và kinh nghiệm nghiên cứu thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp từ quý thầy cô để đề tài được hoàn thiện hơn và có cơ sở phát triển trong tương lai.

Xin chân thành cảm ơn!

An Giang, ngày 12 tháng 3 năm 2026

Sinh viên thực hiện

Huỳnh Nhật Phát

TÓM TẮT

Thị trường tài sản số, đặc biệt là tiền điện tử, có đặc điểm biến động cao, phi tuyến tính và hoạt động liên tục 24/7. Trong bối cảnh đó, các phương pháp giao dịch thủ công thường chịu ảnh hưởng bởi yếu tố cảm xúc và hạn chế về khả năng xử lý thông tin; trong khi đó, các phương pháp học máy có giám sát truyền thống chưa giải quyết trực tiếp được bài toán tối ưu hóa quyết định giao dịch, do chủ yếu tách rời giữa dự báo giá và hành động đầu tư. Trên cơ sở đó, khóa luận này đề xuất một mô hình giao dịch tự động tích hợp giữa trích xuất đặc trưng thị trường và tối ưu hóa chính sách hành động, dựa trên Học tăng cường sâu.

Mục tiêu của nghiên cứu là xây dựng và huấn luyện một hệ thống giao dịch có khả năng phân bổ tỷ trọng tài sản nhằm tối đa hóa lợi nhuận dài hạn đồng thời kiểm soát rủi ro. Bài toán được mô hình hóa dưới dạng Quy trình quyết định Markov. Môi trường mô phỏng giao dịch được xây dựng trên nền tảng Gymnasium, sử dụng dữ liệu lịch sử OHLCV khung 1 giờ của cặp BTC/USDT, kết hợp với các chỉ báo phân tích kỹ thuật và một số đặc trưng liên quan khác. Để tăng tính thực tiễn, môi trường cũng xét đến trượt giá và chi phí giao dịch.

Tác nhân giao dịch được huấn luyện bằng thuật toán Proximal Policy Optimization. Để xử lý không gian trạng thái mang tính chuỗi thời gian, nghiên cứu khảo sát hai kiến trúc bộ trích xuất đặc trưng là GRU và LSTM, kết hợp với cơ chế Attention Pooling nhằm tổng hợp thông tin từ toàn bộ chuỗi quan sát. Biểu diễn đặc trưng thu được sau đó được đưa vào mạng Actor-Critic, sử dụng hàm kích hoạt GeLU và bộ tối ưu AdamW để ước lượng chính sách hành động và phân bổ danh mục. Bên cạnh đó, độ dài episode cũng được tinh chỉnh và đánh giá ở ba mức 720, 2160 và 4320 bước thời gian, tương ứng xấp xỉ 1 tháng, 3 tháng và 6 tháng dữ liệu giao dịch, nhằm khảo sát ảnh hưởng của phạm vi tích lũy phần thưởng đến hiệu năng học của tác nhân. Kết quả thực nghiệm trên tập kiểm thử cho thấy mô hình DRL có khả năng học được chính sách giao dịch hiệu quả. Trong các cấu hình đã khảo sát, mô hình sử dụng bộ trích xuất đặc trưng LSTM với độ dài episode 4320 bước đạt hiệu năng tốt nhất, với lợi nhuận tích lũy đạt 42,11%, tỷ lệ Sharpe đạt 1,10 và mức sụt giảm tối đa được kiểm soát ở mức -12,25%. Kết quả này vượt trội đáng kể so với chiến lược cơ sở. Nghiên cứu cho thấy LSTM phù hợp với việc khai thác đặc trưng từ dữ liệu chuỗi thời gian tài chính dài hạn, đồng thời gợi mở tiềm năng ứng dụng của học tăng cường sâu trong tự động hóa giao dịch tài sản số.

MỤC LỤC

Chương 1. ĐẶT VẤN ĐỀ	1
1.1. TÍNH CẤP THIẾT CỦA ĐỀ TÀI.....	1
1.2. MỤC TIÊU NGHIÊN CỨU CỦA ĐỀ TÀI.....	3
Chương 2. TỔNG QUAN VÀ CƠ SỞ LÝ THUYẾT.....	5
2.1. ĐẶT VẤN ĐỀ	5
2.2. TÌNH HÌNH NGHIÊN CỨU	5
2.2.1. Ứng dụng của học máy có giám sát trong dự báo chuỗi thời gian tài chính.....	5
2.2.2. Các ứng dụng của học tăng cường.....	6
2.3. PHẠM VI CỦA ĐỀ TÀI.....	7
2.4. PHƯƠNG PHÁP NGHIÊN CỨU	7
2.4.1. Phương pháp nghiên cứu lý thuyết	7
2.4.2. Phương pháp nghiên cứu thực nghiệm	7
2.5. CƠ SỞ LÝ THUYẾT	8
2.5.1. Tài sản số	8
2.5.2. Đặc trưng của dữ liệu tài chính.....	8
2.5.3. Cấu trúc dữ liệu chuỗi thời gian OHLCV.....	9
2.5.4. Chỉ báo kỹ thuật.....	10
2.5.4.1. Chỉ báo RSI.....	10
2.5.4.2. Bollinger Bands %B	11
2.5.4.3. Chỉ báo ADX	11
2.5.4.4. Chỉ báo MFI.....	11
2.5.4.5. Chỉ báo Williams %R	12
2.5.4.6. Chỉ báo VWAP	12
2.5.5. Môi trường mô phỏng.....	13
2.5.6. Học tăng cường.....	13
2.5.7. Quy trình quyết định Markov	14

2.5.8. Phân loại các phương pháp giải bài toán học tăng cường theo mô hình môi trường	16
2.5.8.1. Quy hoạch động.....	17
2.5.8.2. Monte Carlo	18
2.5.8.3. Temporal-Difference.....	18
2.5.9. Deep Reinforcement Learning.....	19
2.5.10. Phương pháp Policy Gradient.....	21
2.5.11. Phương pháp Actor-Critic.....	22
2.5.12. Generalized Advantage Estimation.....	23
2.5.13. Proximal Policy Optimization	24
2.5.14. Các thước đo đánh giá hiệu suất giao dịch	26
2.5.14.1. Chiến lược Buy and Hold (B&H).....	26
2.5.14.2. Lợi nhuận tích lũy.....	27
2.5.14.3. Maximum Drawdown.....	27
2.5.14.4. Tỷ lệ Sharpe	28
2.5.15. Hàm kích hoạt GeLU.....	28
2.5.16. Bộ tối ưu AdamW	29
2.5.17. Long Short-Term Memory	29
2.5.18. Gated Recurrent Unit.....	31
2.5.19. Layer Normalization.....	33
Chương 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	34
3.1. MÔ HÌNH TỔNG QUÁT.....	34
3.2. THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU	34
3.2.1. Thu thập dữ liệu.....	34
3.2.2. Kiểm định và làm sạch dữ liệu	35
3.2.3. Khám phá dữ liệu và xử lý chuỗi thời gian	36
3.2.4. Xây dựng đặc trưng	36
3.2.4.1. Đặc trưng gián đoạn thời gian	36
3.2.4.2. Đặc trưng chu kỳ thời gian	37

3.2.4.3. Đặc trưng về thị trường.....	37
3.2.4.4. Tổng hợp đặc trưng.....	39
3.2.5. Phân chia và chuẩn hóa dữ liệu	40
3.3. THIẾT KẾ MÔI TRƯỜNG GIAO DỊCH	41
3.3.1. Mô hình hóa dưới dạng MDP	41
3.3.2. Không gian trạng thái	41
3.3.3. Không gian hành động.....	42
3.3.4. Cơ chế chuyển trạng thái và cập nhật danh mục	43
3.3.4.1. Tính toán tỉ trọng trôi dạt.....	43
3.3.4.2. Ra quyết định chuyển đổi tỷ trọng danh mục.....	43
3.3.4.3. Thực thi lệnh.....	44
3.3.4.4. Cập nhật danh mục cuối kỳ	45
3.3.5. Hàm phần thưởng	45
3.4. THIẾT KẾ TÁC NHÂN	46
3.4.1. Tổng quan kiến trúc	46
3.4.2. Khối trích xuất đặc trưng (Feature Extractor)	46
3.4.3. Khối PPO	50
3.5. THIẾT LẬP THỰC NGHIỆM	51
3.5.1. Các siêu tham số	51
3.5.2. Mô hình huấn luyện	52
3.5.3. Độ dài episode	53
3.5.4. Hàm kích hoạt.....	53
3.5.5. Bộ tối ưu tham số.....	54
3.5.6. Tốc độ học giảm dần.....	54
3.6. KẾT QUẢ THỰC NGHIỆM.....	55
3.6.1. Quá trình huấn luyện	55
3.6.2. Kết quả kiểm thử.....	57
3.6.3. Thảo luận kết quả.....	60
3.6.4. Hạn chế của đề tài.....	60

3.6.5. Kết luận.....	61
3.6.6. Hướng phát triển.....	61
PHỤ LỤC	62
TÀI LIỆU THAM KHẢO	68

DANH SÁCH CÁC HÌNH VẼ

Hình ảnh ở phần nội dung

Hình 2-1. Ví dụ trực quan về biểu đồ nến và ý nghĩa của các mức giá OHLC. Nguồn: Wang và cs. (2021)	9
Hình 2-2. Các phương pháp theo mô hình môi trường.....	17
Hình 2-3. Phân loại theo đối tượng tối ưu	20
Hình 2-4. Long Short-Term Memory. Nguồn: Chung và c.s (2014).....	31
Hình 2-5. Gated Recurrent Unit. Nguồn: Chung và c.s (2014).....	32
Hình 3-1. Sơ đồ tổng quát quá trình thực hiện	34
Hình 3-2. Một mẫu dữ liệu OHLCV	35
Hình 3-3. Đặc trưng tiền xử lý.....	39
Hình 3-4. Kiến trúc mô hình tổng quan.....	46
Hình 3-5. GRU Feature Extractor.....	48
Hình 3-6. LSTM Feature Extractor	49
Hình 3-7. Kiến trúc của khối PPO	50
Hình 3-8. Biểu đồ của mạng GRU-4320	56
Hình 3-9. Biểu đồ của mạng LSTM-4320	57
Hình 3-10. Biểu đồ lợi nhuận tích lũy của GRU-4320 so sánh với B&H.....	58
Hình 3-11. Biểu đồ lợi nhuận tích lũy của LSTM-4320 so sánh với B&H.....	58

Hình ảnh ở phần phụ lục

Hình PL 1. Biểu đồ của mạng GRU-720	63
Hình PL 2. Biểu đồ của mạng GRU-2160	63
Hình PL 3. Biểu đồ của mạng LSTM-720.....	64
Hình PL 4. Biểu đồ của mạng LSTM-2160.....	64
Hình PL 5. Biểu đồ lợi nhuận tích lũy của GRU-720 so sánh với B&H.....	66
Hình PL 6. Biểu đồ lợi nhuận tích lũy của GRU-2160 so sánh với B&H.....	66
Hình PL 7. Biểu đồ lợi nhuận tích lũy của LSTM-720 so sánh với B&H.....	66
Hình PL 8. Biểu đồ lợi nhuận tích lũy của LSTM-2160 so sánh với B&H.....	67

DANH SÁCH CÁC BẢNG BIỂU

Bảng 2-1. Mã giả thuật toán PPO	25
Bảng 3-1. Thông tin các trường dữ liệu.....	34
Bảng 3-2. Phân chia dữ liệu.....	40
Bảng 3-3. Các siêu tham số của mô hình.....	51
Bảng 3-4. Bảng tham số của AdamW.....	54
Bảng 3-5. Kết quả kiểm thử của chiến lược cơ sở.....	58
Bảng 3-6. Kết quả kiểm thử của mô hình	59

DANH SÁCH CÁC TỪ VIẾT TẮT

Từ viết tắt	Tên đầy đủ	Dịch nghĩa
RL	Reinforcement Learning	Học tăng cường
DRL	Deep Reinforcement Learning	Học tăng cường sâu
PPO	Proximal Policy Optimization	
MDP	Markov Decision Process	Quy trình quyết định Markov
DL	Deep Learning	Học sâu
SL	Supervised Learning	Học có giám sát
HFT	High Frequency Trading	Giao dịch tần suất cao
B&H	Buy and hold	Chiến thuật mua và giữ
CR	Cumulative Return	Lợi nhuận tích lũy
DP	Dynamic Programming	Quy hoạch động
TD	Temporal Difference	
MDD	Maximum Drawdown	Mức sụt giảm tối đa
GAE	Generalized Advantage Estimation	Ước tính lợi thế tổng quát
MLP	Multilayer Perceptron	Mạng nơ-ron đa lớp
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
LSTM	Long Short-Term Memory	Mạng bộ nhớ dài-ngắn hạn
GRU	Gated Recurrent Unit	Đơn vị hồi quy có cổng
ReLU	Rectified Linear Unit	Hàm kích hoạt chỉnh lưu tuyến tính
GeLU	Gaussian Error Linear Unit	Hàm kích hoạt tuyến tính lỗi Gauss

Chương 1. ĐẶT VẤN ĐỀ

1.1. TÍNH CẤP THIẾT CỦA ĐỀ TÀI

Thị trường tiền điện tử (cryptocurrency) là một trong những thị trường tài chính có mức độ biến động cao nhất hiện nay, đồng thời chịu ảnh hưởng mạnh bởi tính phi tuyến, tính hỗn loạn và sự xuất hiện thường xuyên của các dao động giá khó dự đoán. Jay và cs. (2020) cho rằng biến động cực đoan của giá tiền điện tử khiến nhiệm vụ dự báo trở nên phức tạp hơn đáng kể so với các thị trường truyền thống. Trong bối cảnh đó, các quyết định giao dịch thủ công ngày càng bộc lộ hạn chế do phụ thuộc vào kinh nghiệm chủ quan, năng lực xử lý thông tin có giới hạn và tác động của cảm xúc trong quá trình ra quyết định.

Trước thực tế này, học có giám sát (Supervised Learning - SL) đã được sử dụng rộng rãi như một hướng tiếp cận nhằm hỗ trợ dự báo xu hướng thị trường. Một số nghiên cứu gần đây, chẳng hạn như Z. Li (2024) với mô hình lai ghép TLACP, cho thấy các mô hình SL có thể đạt độ chính xác cao trong dự báo. Tuy nhiên, hiệu quả dự báo cao không đồng nghĩa với hiệu quả giao dịch thực tế. Như Huang (2018) cũng như Kabbani và Duman (2022) đã chỉ ra, hạn chế cơ bản của SL nằm ở việc tách rời giữa khâu dự báo và khâu ra quyết định. Cụ thể, SL thường chỉ cung cấp tín hiệu dự đoán, trong khi việc chuyển đổi tín hiệu đó thành hành động mua, bán hay nắm giữ vẫn phải dựa vào các quy tắc được thiết kế thủ công. Sự phân tách này làm giảm tính nhất quán giữa mục tiêu dự báo và mục tiêu tối đa hóa lợi nhuận, đồng thời khiến hệ thống khó thích nghi trước sự biến động liên tục của thị trường.

Trong khi đó, học tăng cường (Reinforcement Learning - RL) cho phép mô hình hóa giao dịch như một bài toán ra quyết định tuần tự, trong đó tác nhân học chiến lược tối ưu thông qua tương tác với môi trường thay vì chỉ dừng lại ở việc dự báo giá. Cách tiếp cận này phù hợp hơn với bản chất của hoạt động giao dịch, bởi mục tiêu cốt lõi không phải là dự đoán chính xác từng biến động giá, mà là lựa chọn hành động tối ưu tại từng thời điểm để tối đa hóa lợi ích kỳ vọng trong dài hạn. Trần Kim Toại, Võ Minh Huân, Lê Ngọc Thanh và Võ Thị Xuân Hạnh (2023) đã cho thấy tiềm năng của RL trong giao dịch khi kết hợp với các đặc trưng xu hướng dữ liệu. Tuy nhiên, các thuật toán RL truyền thống vẫn gặp khó khăn khi phải xử lý không gian trạng thái phức tạp, nhiều chiều và có tính phụ thuộc chuỗi theo thời gian (Arulkumaran, Deisenroth, Brundage, & Bharath, 2017).

Để khắc phục hạn chế này, học sâu (Deep Learning - DL) được xem là công cụ quan trọng nhờ khả năng tự động trích xuất các đặc trưng ẩn từ dữ liệu thô phi tuyến tính. Trong các bài toán tài chính, DL đã chứng minh hiệu quả

trong việc mô hình hóa những quan hệ phức tạp mà các phương pháp truyền thống khó nắm bắt (Sezer, Gudelek, & Ozbayoglu, 2019). Khi kết hợp DL với RL, ta thu được học tăng cường sâu (Deep Reinforcement Learning - DRL), trong đó DL đóng vai trò như bộ xấp xỉ hàm phi tuyến mạnh, giúp tác nhân xử lý được không gian trạng thái lớn và giàu thông tin hơn so với RL cổ điển (Arulkumaran và c.s., 2017; Y. Li, 2018b, tr 14). Nhờ đó, DRL mở ra khả năng xây dựng các hệ thống giao dịch tự động có thể trực tiếp học từ dữ liệu thị trường và tự động đưa ra quyết định hành động, thay vì phụ thuộc vào các quy tắc thủ công được thiết lập trước.

Tính hiệu quả của DRL đã được chứng minh trong nhiều nghiên cứu gần đây. Nghiên cứu của Jiang, Xu và Liang (2017) cho thấy DRL có thể hỗ trợ phân bổ vốn tự động một cách hiệu quả. Théate và Ernst (2021) chỉ ra rằng DRL có thể vượt trội hơn chiến lược mua và giữ trong một số thị trường cổ phiếu. Trong bối cảnh giao dịch tần suất cao, Briola, Turiel, Marcaccioli, Cauderan và Aste (2023) cũng cho thấy DRL có thể được áp dụng trên dữ liệu số lệnh để xây dựng chiến lược giao dịch tự động. Những kết quả này cho thấy DRL không chỉ có ý nghĩa về mặt lý thuyết mà còn có tiềm năng ứng dụng thực tiễn trong các môi trường tài chính có độ phức tạp cao.

Trong số các thuật toán DRL, Proximal Policy Optimization (PPO) được đánh giá là một lựa chọn phù hợp cho bài toán giao dịch nhờ cơ chế mục tiêu bị cắt (clipped objective) do Schulman, Wolski, Dhariwal, Radford và Klimov (2017) đề xuất. Cơ chế này giúp hạn chế những cập nhật chính sách quá lớn, từ đó tăng tính ổn định của quá trình huấn luyện và làm cho PPO đặc biệt thích hợp với các bài toán có không gian hành động liên tục. Đây cũng là một trong những lý do thuật toán này được sử dụng trong nhiều nghiên cứu giao dịch dựa trên DRL, bao gồm cả Briola và cs. (2023).

Mặc dù DRL đã được ứng dụng rộng rãi trong giao dịch tài chính, việc thiết kế không gian trạng thái vẫn là một trong những yếu tố quyết định đến hiệu quả của mô hình. Trong tổng quan về ứng dụng DRL cho giao dịch tiền điện tử, Millea (2021) nhấn mạnh rằng biểu diễn trạng thái là thành phần then chốt, có ảnh hưởng trực tiếp đến khả năng học tập và chất lượng ra quyết định của tác nhân. Từ đó có thể thấy, hiệu quả của một hệ thống giao dịch không chỉ phụ thuộc vào thuật toán học tăng cường được lựa chọn, mà còn phụ thuộc rất lớn vào cách xây dựng đầu vào cho mô hình. Đây chính là cơ sở để nghiên cứu này tập trung vào việc thiết kế môi trường giao dịch và cấu trúc trạng thái phù hợp với đặc trưng của dữ liệu thị trường tiền điện tử.

Xuất phát từ những lý do trên, đề tài được thực hiện nhằm giải quyết hai mục tiêu chính. Thứ nhất, xây dựng một môi trường giao dịch tiền điện tử được mô hình hóa dưới dạng quy trình quyết định Markov (Markov Decision Process - MDP) (Y. Li, 2018a, tr 12–13; Sutton & Barto, 2014, tr 47–69), trong đó xác định rõ không gian trạng thái, không gian hành động và hàm phần thưởng, đồng thời triển khai trên nền tảng Gymnasium để bảo đảm khả năng tái lập và tương thích với các framework DRL hiện đại (Towers và c.s., 2025). Thứ hai, huấn luyện tác nhân PPO thông qua thư viện Stable-Baselines3 (Raffin và cs., 2021) và tiến hành thực nghiệm xem xét hiệu suất của tác nhân với không gian trạng thái sử dụng dữ liệu giá thô kết hợp thêm các chỉ báo kỹ thuật và thông tin trạng thái tài khoản. Qua đó, nghiên cứu kỳ vọng góp phần cung cấp một hướng tiếp cận có tính hệ thống hơn cho bài toán giao dịch tiền điện tử bằng DRL, đồng thời bổ sung thêm một nguồn tham khảo thực nghiệm bằng tiếng Việt cho các nghiên cứu liên quan.

1.2. MỤC TIÊU NGHIÊN CỨU CỦA ĐỀ TÀI

Mục tiêu của đề tài là nghiên cứu, xây dựng và đánh giá một tác nhân giao dịch tiền điện tử tự động dựa trên thuật toán PPO trong môi trường giao dịch mô phỏng. Tác nhân được thiết kế nhằm học chiến lược ra quyết định phù hợp với biến động của thị trường, từ đó tối ưu hóa hiệu quả sinh lời đồng thời kiểm soát mức độ rủi ro trong quá trình giao dịch.

Để đạt được mục tiêu tổng quát trên, đề tài tập trung thực hiện các mục tiêu cụ thể sau.

Thứ nhất, hệ thống hóa và làm rõ cơ sở lý thuyết liên quan đến MDP trong bài toán tài chính, nguyên lý hoạt động của DRL, cũng như cơ chế hoạt động của thuật toán PPO trong các bài toán ra quyết định tuần tự.

Thứ hai, thiết kế và lập trình môi trường giao dịch tiền điện tử theo chuẩn giao diện Gymnasium, mô phỏng bài toán giao dịch giao ngay với các thành phần cơ bản của thị trường, làm cơ sở cho việc huấn luyện và kiểm thử tác nhân.

Thứ ba, nghiên cứu và tích hợp các kiến trúc mô hình trích xuất đặc trưng khác nhau vào tác nhân PPO, bao gồm GRU và LSTM, nhằm khai thác đặc trưng từ dữ liệu thị trường theo các góc nhìn biểu diễn khác nhau. Trên cơ sở đó, đề tài tiến hành so sánh và đánh giá hiệu quả của các cấu hình mô hình khi kết hợp với PPO trong cùng một môi trường thực nghiệm.

Thứ tư, đánh giá hiệu quả của mô hình thông qua các chỉ số tài chính tiêu chuẩn, bao gồm lợi nhuận tích lũy (Cumulative Return - CR), tỷ lệ Sharpe và độ sụt giảm tài sản tối đa (Maximum Drawdown - MDD). Kết quả thực nghiệm

được đối chiếu với chiến lược cơ sở Mua và Giữ (Buy and Hold - B&H) để xem xét mức độ hiệu quả của mô hình đề xuất.

Chương 2. TỔNG QUAN VÀ CƠ SỞ LÝ THUYẾT

2.1. ĐẶT VẤN ĐỀ

Trong bối cảnh thị trường tiền điện tử hoạt động liên tục 24/7 với biên độ dao động giá vô cùng lớn và tính bất định cao, bài toán cốt lõi đặt ra cho các nhà đầu tư là xây dựng một chiến lược giao dịch tối ưu, ổn định và loại bỏ được yếu tố cảm xúc. Khác với thị trường tài chính truyền thống, đặc thù vận hành không ngừng nghỉ này buộc nhà đầu tư phải liên tục quan sát trạng thái thị trường, đưa ra quyết định phân bổ tài sản và quản trị rủi ro theo thời gian thực.

Mặc dù các hệ thống giao dịch thuật toán hiện hành và các mô hình học máy đã đạt được nhiều thành tựu đáng kể trong việc phân tích và dự báo chuỗi thời gian tài chính, cách tiếp cận truyền thống thường phân tách bài toán thành hai giai đoạn độc lập: dự báo xu hướng giá trị tương lai và thiết lập hệ thống quy tắc hành động dựa trên dự báo đó. Phương pháp tiếp cận này mang lại sự minh bạch trong cấu trúc, nhưng đòi hỏi sự can thiệp và hiệu chỉnh liên tục để duy trì tính hiệu quả khi cấu trúc thị trường biến động. Thêm vào đó, việc ánh xạ trực tiếp kết quả dự báo thành một chiến lược quản lý vốn và phân bổ tài sản tối ưu theo thời gian thực vẫn là một thách thức phức tạp. Do đó, một hướng nghiên cứu đầy triển vọng được đặt ra là phát triển các hệ thống có khả năng tích hợp liền mạch giữa việc trích xuất đặc trưng thị trường và tối ưu hóa chính sách hành động tổng thể.

Từ những cơ sở trên, nhu cầu thiết thực là nghiên cứu và xây dựng một tác nhân thông minh có khả năng tự động hoá quy trình giao dịch. Đề tài này đặt ra bài toán: thiết kế một môi trường mô phỏng giao dịch tài sản số giống với thực tế và ứng dụng DRL để huấn luyện tác nhân. Thông qua các thuật toán tối ưu hóa chính sách tiên tiến như PPO, hệ thống sẽ học cách tương tác với dữ liệu thị trường và tự động đưa ra các quyết định giao dịch liên tục, hướng tới mục tiêu tối ưu hoá lợi nhuận tích lũy dài hạn đồng thời kiểm soát chặt chẽ rủi ro.

2.2. TÌNH HÌNH NGHIÊN CỨU

2.2.1. Ứng dụng của học máy có giám sát trong dự báo chuỗi thời gian tài chính

Dự báo chuỗi thời gian tài chính là một hướng nghiên cứu lâu đời, phát triển từ các mô hình thống kê cổ điển sang các phương pháp học máy có giám sát và gần đây là DL (Rundo, Trenta, Di Stallo, & Battiato, 2019; Shah, Vaidya, & Shah, 2022). Nhìn chung, các nghiên cứu trong nhánh này xem bài toán như một bài toán dự báo, trong đó mô hình học từ dữ liệu quá khứ để ước lượng giá hoặc lợi suất trong một chân trời dự báo nhất định chẳng hạn như 1 giờ hoặc 1

ngày. Tổng quan của Sezer, Gudelek và Ozbayoglu (2019) hệ thống hóa các hướng tiếp cận chủ đạo và cho thấy xu thế chuyển dịch từ đặc trưng thủ công kết hợp mô hình học máy sang các kiến trúc DL có khả năng tự trích xuất đặc trưng.

Trên nền đó, nhiều kiến trúc DL đã được áp dụng cho dự báo tài chính như CNN, RNN, GRU, LSTM, Autoencoder và Transformer, cũng như các mô hình lai kết hợp nhiều kiến trúc nhằm tận dụng đồng thời khả năng trích xuất đặc trưng cục bộ và mô hình hóa phụ thuộc dài hạn; ví dụ, Li (2024) đề xuất kiến trúc kết hợp Transformer–CNN–LSTM cho dự báo thị trường. Bên cạnh các kiến trúc này, một số nghiên cứu còn đề xuất biến thể mạng nơ-ron mang tính ngẫu nhiên để biểu diễn tốt hơn bất định trong dữ liệu, và được Jay và cs. (2020) thảo luận trong bối cảnh dự báo tài sản tiền điện tử.

Tuy nhiên, dự báo chính xác không đồng nghĩa với hiệu quả giao dịch cao. Trong phần lớn các thiết kế dựa trên học có giám sát, mô-đun dự báo thường tách rời mô-đun ra quyết định, việc này đã được đề cập trong nghiên cứu của Huang (2018) cũng như Kabbani và Duman (2022). Mô hình xuất ra giá, sau đó một tập luật giao dịch hoặc chiến lược phụ được xây dựng để quyết định mua/bán. Cách tiếp cận hai giai đoạn này tạo ra độ lệch mục tiêu là mô hình tối ưu hóa sai số dự báo, trong khi mục tiêu thực tế của giao dịch là tối ưu hóa lợi nhuận giảm thiểu rủi ro. Vì vậy, ngay cả khi mô hình dự báo đúng theo nghĩa thống kê, chiến lược giao dịch suy ra từ dự báo vẫn có thể kém hiệu quả hoặc rủi ro cao. Hạn chế này gợi mở nhu cầu về một khung ra quyết định có khả năng tối ưu hóa trực tiếp mục tiêu giao dịch, thay vì tối ưu hóa sai số dự báo, đây chính là hướng tiếp cận của RL.

2.2.2. Các ứng dụng của học tăng cường

Khác với cách tiếp cận dự báo rồi ra quyết định ở trên, RL cho phép tác nhân tối ưu hóa trực tiếp mục tiêu giao dịch mà không cần mô-đun quyết định riêng biệt. Môi trường giao dịch được mô hình hóa dưới dạng MDP, trong đó tác nhân quan sát trạng thái thị trường, thực hiện hành động mua bán và nhận phần thưởng phản ánh hiệu quả giao dịch. Thông qua quá trình tương tác lặp đi lặp lại với môi trường mô phỏng, tác nhân tự phát triển chiến lược giao dịch hướng tới tối đa hóa lợi nhuận tích lũy.

Các thuật toán RL đã được ứng dụng rộng rãi trong nhiều bài toán tài chính. Trong giao dịch cổ phiếu, Kabbani và Duman (2022) cùng với Théate và Ernst (2021) cho thấy tác nhân RL có thể đưa ra quyết định mua/bán hiệu quả trên dữ liệu lịch sử. Jiang, Xu và Liang (2017) áp dụng RL cho bài toán quản lý danh mục đầu tư. Trong lĩnh vực giao dịch tần suất cao, Briola và cs. (2023)

khai thác dữ liệu Limit Order Book kết hợp RL. Ngoài ra, RL cũng được nghiên cứu trên thị trường tiền điện tử và ngoại hối (Huang, 2018; Trần và c.s., 2023; Zhang, Zohren, & Roberts, 2019).

2.3. PHẠM VI CỦA ĐỀ TÀI

Đề tài tập trung nghiên cứu và xây dựng môi trường mô phỏng giao dịch tiền điện tử, đồng thời ứng dụng thuật toán PPO để huấn luyện tác nhân giao dịch tự động. Phạm vi nghiên cứu được giới hạn trong dữ liệu giá lịch sử của thị trường tiền điện tử và các đặc trưng kỹ thuật được sử dụng làm đầu vào cho mô hình.

Về phương pháp, đề tài chỉ xem xét một tác nhân giao dịch trong môi trường mô phỏng, với không gian hành động liên tục biểu diễn tỷ trọng nắm giữ tài sản. Nghiên cứu không đi sâu vào triển khai giao dịch thực tế trên thị trường, không xét đến các yếu tố ngoại sinh như tin tức, tâm lý thị trường hay tác động vĩ mô ngoài phạm vi dữ liệu đầu vào đã xây dựng.

Về đánh giá, hiệu quả của mô hình được xem xét thông qua một số chỉ tiêu tài chính cơ bản như lợi nhuận tích lũy, tỷ lệ Sharpe và mức sụt giảm tài sản tối đa, đồng thời so sánh với chiến lược mua và giữ.

2.4. PHƯƠNG PHÁP NGHIÊN CỨU

2.4.1. Phương pháp nghiên cứu lý thuyết

Đề tài tiến hành tổng hợp, phân tích và hệ thống hóa các tài liệu, công trình nghiên cứu liên quan đến học tăng cường, thuật toán Proximal Policy Optimization, lý thuyết quy trình quyết định Markov và các ứng dụng của chúng trong giao dịch tài chính. Trên cơ sở đó, nghiên cứu xây dựng khung lý thuyết làm nền tảng cho việc mô hình hóa bài toán giao dịch tiền điện tử dưới góc độ học tăng cường.

2.4.2. Phương pháp nghiên cứu thực nghiệm

Nghiên cứu được triển khai theo hướng thực nghiệm thông qua các bước chính sau:

Trước hết, dữ liệu giá lịch sử theo khung thời gian 1 giờ của Bitcoin (BTC) được thu thập từ sàn giao dịch Binance. Dữ liệu sau đó được làm sạch, xử lý và chuẩn hóa nhằm bảo đảm chất lượng đầu vào cho mô hình.

Tiếp theo, môi trường giao dịch được xây dựng theo chuẩn giao diện Gymnasium và mô hình hóa theo quy trình MDP. Môi trường mô phỏng giao dịch giao ngay (Spot Trading), có tích hợp phí giao dịch cố định 0,1% và trượt giá theo hướng bất lợi đối với vị thế hiện tại.

Sau đó, tác nhân được huấn luyện bằng thuật toán PPO thông qua thư viện Stable-Baselines3, kết hợp với các lớp trích xuất đặc trưng như LSTM và GRU để khai thác đặc trưng từ chuỗi dữ liệu đầu vào.

Cuối cùng, mô hình được đánh giá trên tập kiểm thử chưa từng được sử dụng trong quá trình huấn luyện. Hiệu suất của tác nhân được xem xét thông qua các chỉ số tài chính cơ bản và được so sánh với chiến lược cơ sở.

2.5. CƠ SỞ LÝ THUYẾT

2.5.1. Tài sản số


Tài sản số là các loại tài sản tồn tại dưới dạng dữ liệu điện tử và được ghi nhận, lưu trữ, chuyển giao thông qua hạ tầng số. Trong phạm vi nghiên cứu này, tài sản số được hiểu chủ yếu là tiền điện tử, một dạng tài sản phi tập trung được giao dịch trên các nền tảng công nghệ số và có giá trị biến động theo cung, cầu của thị trường. So với các tài sản tài chính truyền thống, tài sản số có đặc trưng là mức độ phi tập trung cao, khả năng giao dịch liên tục 24/7, chi phí tham gia thấp và biên độ dao động giá lớn. Những đặc điểm này làm cho tài sản số vừa mang lại cơ hội sinh lời cao, vừa tiềm ẩn rủi ro đáng kể, từ đó đặt ra yêu cầu đối với các mô hình giao dịch có khả năng thích nghi tốt với biến động thị trường.

2.5.2. Đặc trưng của dữ liệu tài chính

Dữ liệu tài chính thường được biểu diễn dưới dạng chuỗi thời gian OHLCV, gồm giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và khối lượng giao dịch tại từng thời điểm. Đây là dạng dữ liệu tiêu chuẩn trong các hệ thống giao dịch thuật toán. Tuy nhiên, dữ liệu OHLCV có nhiều đặc trưng thống kê gây khó khăn cho quá trình mô hình hóa, gồm tính non-stationary, sự chênh lệch lớn về thang đo giữa các đặc trưng và hiện tượng phân phối lợi suất có đuôi dày.

Trong thực tế, các đặc trưng này thể hiện rõ hơn ở thị trường tiền điện tử do thị trường hoạt động liên tục, biến động mạnh và thanh khoản phân bố không đồng đều giữa các tài sản và các sàn giao dịch. Vì vậy, dữ liệu đầu vào cần được tiền xử lý và chuẩn hóa phù hợp để bảo đảm mô hình học sâu có thể hội tụ ổn định và tổng quát hóa tốt.

2.5.3. Cấu trúc dữ liệu chuỗi thời gian OHLCV



Hình 2-1. Ví dụ trực quan về biểu đồ nến và ý nghĩa của các mức giá OHLC.
Nguồn: Wang và cs. (2021)

Thị trường tài chính vận hành liên tục thông qua cơ chế khớp lệnh trên sổ lệnh giới hạn (Limit Order Book), qua đó tạo ra một dòng dữ liệu giao dịch vi mô có tần suất rất cao và chịu ảnh hưởng đáng kể của nhiễu ngẫu nhiên. Để phục vụ cho việc phân tích và mô hình hóa, dòng dữ liệu này thường được rời rạc hóa theo các khoảng thời gian cố định, chẳng hạn 1 giờ, nhằm thu được chuỗi thời gian có cấu trúc rõ ràng hơn. Kết quả của quá trình này là chuỗi thời gian OHLCV, một biểu diễn đa biến cô đọng thông tin về biến động giá và mức độ giao dịch trong từng phiên. Trong mỗi khoảng thời gian, trạng thái thị trường được mô tả thông qua năm thành phần gồm giá mở cửa (Open), giá cao nhất (High), giá thấp nhất (Low), giá đóng cửa (Close) và khối lượng giao dịch (Volume).

Để trực quan hóa quá trình nén dữ liệu giao dịch vi mô thành các đại lượng rời rạc, cấu trúc giá Open, High, Low, Close (OHLC) thường được biểu diễn dưới dạng biểu đồ nến. Như minh họa ở Hình 2-1, biến thiên giá liên tục trong một khoảng thời gian được cô đọng thành một cây nến duy nhất, qua đó phản ánh trực quan mức chênh lệch và giới hạn dao động của giá trong phiên. Dạng biểu diễn này cho phép mô tả ngắn gọn và nhất quán trạng thái thị trường trong từng khoảng thời gian, đồng thời phản ánh các ràng buộc nội tại của dữ liệu OHLC trong quá trình mô hình hóa. Trên cơ sở đó, chuỗi OHLC được mở rộng bằng cách bổ sung thêm khối lượng giao dịch, từ đó hình thành cấu trúc OHLCV. Dựa trên cách biểu diễn của Wang và cs. (2021), chuỗi OHLC được mở rộng thành cấu trúc OHLCV dưới dạng vector cột tại thời điểm t như sau:

$$\mathbf{x}_t = [x_t^{(o)}, x_t^{(h)}, x_t^{(l)}, x_t^{(c)}, x_t^{(v)}]^T \in \mathbb{R}^5 \quad (2-1)$$

Trong đó, $x_t^{(o)}$, $x_t^{(h)}$, $x_t^{(l)}$, $x_t^{(c)}$, $x_t^{(v)}$ lần lượt đại diện cho giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và tổng khối lượng giao dịch và ký hiệu T là toán tử chuyển vị. Các thành phần này thỏa mãn các ràng buộc nội tại của dữ liệu giá, cụ thể là $x_t^{(o)} > 0$; $x_t^{(l)} < x_t^{(h)}$; $x_t^{(o)}, x_t^{(c)} \in [x_t^{(l)}, x_t^{(h)}]$ và $x_t^{(v)} \geq 0$.

Khi xét một cửa sổ quan sát từ thời điểm t đến T gồm $N = T - t + 1$ nến, toàn bộ chuỗi OHLCV được viết dưới dạng ma trận như sau:

$$\mathbf{X}_{t:T} = \begin{bmatrix} \mathbf{x}_t^\top \\ \mathbf{x}_{t+1}^\top \\ \vdots \\ \mathbf{x}_T^\top \end{bmatrix} \in \mathbb{R}^{N \times 5} \quad (2-2)$$

Trong khuôn khổ này, chỉ số t đóng vai trò là chỉ số thứ tự của quan sát trong chuỗi rời rạc, còn mỗi phần tử của chuỗi tương ứng với một mốc thời gian cố định trên lưới thời gian 1 giờ.

2.5.4. Chỉ báo kỹ thuật

Trong phân tích chuỗi thời gian tài chính, dữ liệu OHLCV nguyên bản thường chứa đựng một lượng lớn nhiễu ngẫu nhiên do các giao dịch vi mô gây ra. Để mô hình hóa các động lực học cốt lõi, dữ liệu thô cần được biến đổi thông qua các hàm toán học, được gọi chung là các chỉ báo kỹ thuật (Technical Indicators).

Dựa trên không gian trạng thái OHLCV đã được thiết lập tại mục 2.5.3, toàn bộ các tính toán chỉ báo tại thời điểm t sẽ kế thừa và sử dụng trực tiếp các thành phần đã được định nghĩa ở đó.

Về mặt đại số, một chỉ báo kỹ thuật là một hàm biến đổi $f(\cdot)$ ánh xạ một tập hợp con các trạng thái thị trường trong một khoảng thời gian quan sát w thành một đại lượng vô hướng hoặc một vector đặc trưng mới:

$$I_t = f(\mathbf{X}_{t-w+1:t}) \quad (2-3)$$

Trong đó $\mathbf{X}_{t-w+1:t}$ là ma trận dữ liệu OHLCV từ thời điểm $t - w + 1$ đến t được định nghĩa ở công thức (2-2).

Các chỉ báo kỹ thuật trong nghiên cứu này được định nghĩa và triển khai dựa trên tiêu chuẩn thuật toán của thư viện phân tích kỹ thuật TA-Lib (2026). Sau đây là các chỉ báo kỹ thuật sẽ sử dụng trong nghiên cứu này.

2.5.4.1. Chỉ báo RSI

Chỉ báo RSI giúp đo lường động lượng, đánh giá tốc độ và biên độ thay đổi giá để xác định vùng quá mua hoặc quá bán của tài sản. Trong nghiên cứu này, RSI được tính trên cửa sổ trượt w kỳ, với công thức tổng quát:

$$RSI_t^{(w)} = 100 - \frac{100}{1 + RS_t^{(w)}} \in [0, 100] \quad (2-4)$$

Với chỉ số $RS_t^{(w)}$ là tỷ lệ giữa mức tăng trung bình và mức giảm trung bình trong w kỳ gần nhất, được xác định bởi:

$$RS_t^{(w)} = \frac{AG_t^{(w)}}{AL_t^{(w)}} \quad (2-5)$$

Trong đó, đại lượng $AG_t^{(w)}$ là mức tăng trung bình, $AL_t^{(w)}$ là mức giảm trung bình trong w kỳ gần nhất tính đến thời điểm t .

2.5.4.2. Bollinger Bands %B

Chỉ báo Bollinger Bands %B giúp định lượng hóa vị trí tương đối của mức giá trong khung biến động, hỗ trợ đánh giá mối tương quan giữa giá hiện tại với các dải biên để xác định trạng thái quá mua, quá bán hoặc các điểm bứt phá xu hướng. Trong nghiên cứu này, %B được tính trên cửa sổ trượt w kỳ, với công thức tổng quát:

$$\%B_t^{(w)} = \frac{x_t^{(c)} - LB_t^{(w)}}{UB_t^{(w)} - LB_t^{(w)}} \in \mathbb{R} \quad (2-6)$$

Trong đó, $UB_t^{(w)}$ là giá trị dải trên, $LB_t^{(w)}$ là giá trị dải dưới tại thời điểm t , tính theo cửa sổ w .

2.5.4.3. Chỉ báo ADX

Chỉ báo ADX giúp đo lường cường độ của một xu hướng giá mà không phụ thuộc vào hướng đi của xu hướng đó, hỗ trợ xác định trạng thái thị trường đang có xu hướng mạnh hay đang tích lũy. Trong nghiên cứu này, ADX được tính trên cửa sổ trượt w kỳ, với công thức tổng quát:

$$ADX_t^{(w)} = \frac{1}{w} \sum_{i=0}^{w-1} DX_{t-i} \in [0, 100] \quad (2-7)$$

Trong đó, chỉ số hướng DX_t được xác định bởi:

$$DX_t = 100 \frac{|DI_t^{+(w)} - DI_t^{-(w)}|}{DI_t^{+(w)} + DI_t^{-(w)}} \quad (2-8)$$

Với $DI_t^{+(w)}$ là chỉ số định hướng dương đại diện cho áp lực tăng giá, $DI_t^{-(w)}$ là chỉ số định hướng âm, đại diện cho áp lực giảm giá.

2.5.4.4. Chỉ báo MFI

Chỉ báo MFI là một công cụ đo lường động lượng, giúp đánh giá áp lực mua và bán của tài sản bằng cách kết hợp cả dữ liệu về giá và khối lượng giao

dịch. MFI cung cấp cái nhìn về cường độ dòng tiền đổ vào hoặc rút ra khỏi tài sản. Trong nghiên cứu này, MFI được tính trên cửa sổ trượt w kỳ, với công thức tổng quát:

$$MFI_t^{(w)} = 100 - \frac{100}{1 + MR_t^{(w)}} \in [0, 100] \quad (2-9)$$

Trong đó, tỷ số dòng tiền $MR_t^{(w)}$ là tỷ lệ giữa dòng tiền dương và dòng tiền âm trong cửa sổ w được xác định bởi:

$$MR_t^{(w)} = \frac{PMF_t^{(w)}}{NMF_t^{(w)}} \quad (2-10)$$

Với $PMF_t^{(w)}$ đại diện cho tổng lượng tiền đổ vào tài sản khi giá có xu hướng tăng, $NMF_t^{(w)}$ đại diện cho tổng lượng tiền rút ra khỏi tài sản khi giá có xu hướng giảm trong cửa sổ w .

2.5.4.5. Chỉ báo Williams %R

Chỉ báo Williams %R là một chỉ báo động lượng giúp xác định các vùng quá mua và quá bán của tài sản, chỉ báo này phản ánh tốc độ biến động giá một cách nhạy bén, thường được sử dụng để dự báo các điểm đảo chiều sớm. Trong nghiên cứu này, Williams %R được tính trên cửa sổ trượt w kỳ, với công thức tổng quát:

$$W\%R_t^{(w)} = -100 \frac{H_t^{(w)} - x_t^{(c)}}{H_t^{(w)} - L_t^{(w)}} \in [-100, 0] \quad (2-11)$$

Trong đó, $H_t^{(w)} = \max\{x_i^{(h)} \mid t - w + 1 \leq i \leq t\}$ là mức giá cao nhất ghi nhận được, $L_t^{(w)} = \min\{x_i^{(l)} \mid t - w + 1 \leq i \leq t\}$ là mức giá thấp nhất ghi nhận được trong cửa sổ trượt w kỳ tính đến thời điểm t .

2.5.4.6. Chỉ báo VWAP

Chỉ báo VWAP cung cấp mức giá trung bình của tài sản được giao dịch dựa trên khối lượng giao dịch trong một khoảng thời gian xác định. VWAP phản ánh giá trị thực của thị trường bằng cách ưu tiên các mức giá có khối lượng giao dịch lớn, giúp xác định các vùng thanh khoản và điểm xoay xu hướng quan trọng. Trong nghiên cứu này, VWAP được tính trên cửa sổ trượt w kỳ, với công thức tổng quát:

$$VWAP_t^{(w)} = \frac{\sum_{i=t-w+1}^t (TP_i \cdot x_i^{(v)})}{\sum_{i=t-w+1}^t x_i^{(v)}} \quad (2-12)$$

Với TP_i là giá điển hình tại thời điểm i , được tính bởi công thức:

$$TP_i = \frac{x_i^{(h)} + x_i^{(l)} + x_i^{(c)}}{3} \quad (2-13)$$

2.5.5. Môi trường mô phỏng

Trong học tăng cường, tác nhân học thông qua tương tác với môi trường bằng cách quan sát trạng thái, thực hiện hành động và nhận phần thưởng. Tuy nhiên, việc huấn luyện trực tiếp trên thị trường thực là không phù hợp do chi phí cao, thời gian huấn luyện dài và khó bảo đảm tính tái lập của thí nghiệm.

Vì vậy, môi trường mô phỏng được sử dụng để tái hiện cơ chế vận hành của thị trường dựa trên dữ liệu lịch sử. Cách tiếp cận này cho phép tác nhân tương tác nhiều lần mà không phát sinh rủi ro tài chính thực tế, đồng thời tạo điều kiện đánh giá khách quan giữa các chiến lược khác nhau. Trong nghiên cứu này, môi trường mô phỏng được xây dựng theo chuẩn giao diện Gymnasium, với các thành phần cơ bản bao gồm `reset()`, `step(action)`, `observation space` và `action space`. Cấu trúc này giúp môi trường dễ dàng tích hợp với các thư viện huấn luyện RL như Stable-Baselines3, đồng thời bảo đảm tính mô-đun và khả năng tái sử dụng của hệ thống.

2.5.6. Học tăng cường

RL là một nhánh của học máy, trong đó tác nhân học cách hành xử thông qua tương tác trực tiếp với môi trường theo cơ chế thử-sai (trial-and-error). Khác với phương pháp học có giám sát khi mô hình được cung cấp tập dữ liệu bao gồm các cặp đầu vào và nhãn tương ứng, tác nhân trong RL không được chỉ định trước hành động tối ưu cho từng trạng thái cụ thể. Thay vào đó, tác nhân phải tự khám phá bằng cách thực hiện hành động, nhận phản hồi dưới dạng phần thưởng từ môi trường, rồi điều chỉnh chiến lược của mình. RL cũng khác với học không giám sát, mục tiêu không phải tìm cấu trúc ẩn trong dữ liệu mà là tìm chiến lược hành động tối đa hóa tổng phần thưởng tích lũy theo thời gian (Sutton & Barto, 2014, tr 1–2). Về mặt bản chất, RL xem bài toán như một quá trình ra quyết định tuần tự, trong đó tác nhân tương tác với môi trường và tìm cách tối đa hóa tổng phần thưởng nhận được.

Một đặc trưng then chốt phân biệt RL với các nhánh học máy khác là sự đánh đổi giữa khai thác và khám phá. Tác nhân phải cân bằng giữa việc khai thác những hành động đã biết mang lại phần thưởng cao và việc khám phá những hành động mới có thể tốt hơn trong dài hạn. Nếu chỉ khai thác, tác nhân có thể mắc kẹt ở giải pháp tầm thường; nếu chỉ khám phá, tác nhân không tận dụng được kiến thức đã tích lũy. Đây là thách thức không xuất hiện trong học có giám sát hay học không giám sát (Sutton & Barto, 2014, tr 3).

Đặc trưng quan trọng thứ hai là tính tuần tự của quyết định. Trong nhiều bài toán, một hành động không chỉ ảnh hưởng đến phần thưởng tức thời mà còn định hình trạng thái tiếp theo của môi trường, qua đó tác động đến toàn bộ chuỗi phần thưởng trong tương lai. Tác nhân do đó cần xem xét hệ quả dài hạn của mỗi quyết định, chứ không chỉ tối ưu cục bộ tại từng bước. Chính đặc trưng này khiến bài toán RL cần một khuôn khổ toán học nghiêm ngặt để mô hình hóa quá trình ra quyết định tuần tự dưới tính bất định. Khuôn khổ được sử dụng rộng rãi nhất là MDP, được Sutton và Barto (2014) trình bày như nền tảng toán học cốt lõi của RL.

2.5.7. Quy trình quyết định Markov

MDP là một khuôn khổ toán học được sử dụng để mô hình hóa quá trình ra quyết định tuần tự, trong đó các trạng thái chuyển đổi dựa trên những quy luật xác suất nhất định. MDP cung cấp phương pháp hình thức hóa việc ra quyết định theo từng bước thời gian rời rạc; tại đây, mỗi hành động không chỉ mang lại phần thưởng tức thời mà còn ảnh hưởng trực tiếp đến các trạng thái và phần thưởng trong tương lai. Có thể hiểu đơn giản, MDP mô phỏng cách thức học hỏi từ sự tương tác với môi trường để đạt được mục tiêu cốt lõi.

Thành phần chính của hệ thống bao gồm người ra quyết định, được gọi là tác nhân và thế giới bên ngoài mà tác nhân tương tác, được gọi là môi trường. Quá trình tương tác này diễn ra liên tục: tác nhân thực hiện một hành động tác động lên môi trường, môi trường sau đó phản hồi bằng một phần thưởng là một giá trị số phản ánh mức độ tốt hay xấu của hành động mà tác nhân luôn tìm cách tối đa hóa và trạng thái tiếp theo của môi trường.

Cụ thể hơn, tác nhân và môi trường tương tác với nhau ở chuỗi các bước thời gian rời rạc $t = 0, 1, 2, 3, \dots$. Tại mỗi bước thời gian t , tác nhân nhận được vài trạng thái biểu diễn của môi trường là $S_t \in \mathcal{S}$, và trên cơ sở đó thực hiện hành động $A_t \in \mathcal{A}(S_t)$. Ở bước tiếp theo, như là của hệ quả hành động đó, tác nhân nhận được một số là phần thưởng $R_{t+1} \in \mathcal{R} \subset \mathbb{R}$ và môi trường chuyển sang trạng thái mới S_{t+1} . Chuỗi tương tác này tạo ra một quỹ đạo có dạng $\tau = [S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \dots]$ (Sutton & Barto, 2014, tr 47–48; Zhang và c.s., 2019, tr 3). Tùy thuộc vào bản chất của bài toán, chuỗi tương tác này có thể chia thành hai loại là chuỗi liên tục vô hạn hoặc chuỗi bị chia nhỏ thành các chuỗi con hữu hạn, mỗi chuỗi con đó được gọi là một tập (episode).

Đặc trưng quan trọng nhất của MDP là tính chất Markov. Tính chất này được hiểu là xác suất chuyển sang trạng thái tiếp theo và nhận phần thưởng chỉ phụ thuộc vào trạng thái và hành động hiện tại, không phụ thuộc vào toàn bộ

lịch sử trước đó. Tính chất này được thể hiện qua hàm động lực của MDP (Sutton & Barto, 2014, tr 49):

$$p(s', r | s, a) = \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\} \quad (2-14)$$

Hàm bốn đối số p hoàn toàn đặc trưng cho động lực của một MDP hữu hạn. Từ hàm này có thể suy ra xác suất chuyển trạng thái:

$$p(s' | s, a) = \sum_{r \in \mathcal{R}} p(s', r | s, a) \quad (2-15)$$

Phần thưởng kỳ vọng cho mỗi cặp trạng thái–hành động:

$$r(s, a) = \mathbb{E}[R_t | S_{t-1} = s, A_{t-1} = a] = \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} p(s', r | s, a) \quad (2-16)$$

Mục tiêu của tác nhân không phải là tối đa hóa phần thưởng tức thời mà là tối đa hóa tổng phần thưởng tích lũy trong dài hạn, được gọi là lợi nhuận G_t . Đối với các nhiệm vụ theo tập (episodic tasks), lợi nhuận G_t chỉ đơn giản là tổng phần thưởng cho đến bước thời gian cuối cùng T của tập đó, ký hiệu là:

$$G_t = \sum_{t=0}^T R_t \quad (2-17)$$

Với các nhiệm vụ liên tục (continuing tasks) nơi quá trình tương tác diễn ra vô hạn với $T = \infty$. Để đảm bảo tổng này hội tụ và phản ánh sự ưu tiên thời gian, một hệ số chiết khấu $\gamma \in [0, 1]$ được đưa vào (Sutton & Barto, 2014, tr 54–55):

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \quad (2-18)$$

Theo Sutton và Barto (2014, tr 58), để xác định cách hành động tại mỗi trạng thái, tác nhân tuân theo một chính sách π , được định nghĩa là ánh xạ từ trạng thái sang phân phối xác suất trên các hành động. Cụ thể, $\pi(a | s)$ biểu thị xác suất tác nhân chọn hành động a khi đang ở trạng thái s :

$$\pi(a | s) = \Pr\{A_t = a | S_t = s\} \quad (2-19)$$

Để đánh giá mức độ tốt của một trạng thái hoặc một cặp trạng thái–hành động dưới một chính sách nhất định, hai hàm giá trị được sử dụng. Hàm giá trị trạng thái (state-value function) $v_\pi(s)$ cho biết lợi nhuận kỳ vọng khi bắt đầu từ trạng thái s và tuân theo chính sách π :

$$v_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_\pi[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s] \quad (2-20)$$

Hàm giá trị hành động $q_\pi(s, a)$ cho biết lợi nhuận kỳ vọng khi thực hiện hành động a tại trạng thái s rồi tiếp tục tuân theo chính sách π :

$$q_\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a] \quad (2-21)$$

Các hàm giá trị này thỏa mãn một mối quan hệ đệ quy được gọi là phương trình Bellman. Đối với hàm giá trị trạng thái, phương trình Bellman có dạng (Sutton & Barto, 2014, tr 59):

$$v_{\pi}(s) = \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')] \quad (2-22)$$

Phương trình này diễn đạt rằng giá trị của một trạng thái bằng tổng có trọng số của phần thưởng tức thời và giá trị chiết khấu của trạng thái kế tiếp, tính trên tất cả các hành động có thể chọn và tất cả các trạng thái kế tiếp có thể xảy ra.

Chính sách tối ưu π^* là chính sách mang lại lợi nhuận kỳ vọng cao nhất tại mọi trạng thái. Hàm giá trị tương ứng với chính sách tối ưu thỏa mãn phương trình Bellman tối ưu (Sutton & Barto, 2014, tr 62–63):


$$v_*(s) = \max_a \sum_{s', r} p(s', r | s, a) [r + \gamma v_*(s')] \quad (2-23)$$

$$q_*(s, a) = \sum_{s', r} p(s', r | s, a) \left[r + \gamma \max_{a'} q_*(s', a') \right] \quad (2-24)$$

Về mặt lý thuyết, nếu biết đầy đủ hàm động lực p của môi trường, có thể giải trực tiếp các phương trình Bellman tối ưu bằng quy hoạch động. Tuy nhiên, trong thực tế, phần lớn các bài toán có không gian trạng thái quá lớn hoặc hàm động lực không được biết trước, khiến cách tiếp cận này không khả thi. Đây chính là động lực dẫn đến sự phát triển của các phương pháp RL, cho phép tác nhân học chính sách tối ưu thông qua tương tác trực tiếp với môi trường mà không cần mô hình hóa đầy đủ hàm động lực (Sutton & Barto, 2014, tr 67–69).

2.5.8. Phân loại các phương pháp giải bài toán học tăng cường theo mô hình môi trường

Các phương pháp giải bài toán RL được chia thành hai nhóm chính dựa trên việc tác nhân có sử dụng mô hình động lực $p(s', r | s, a)$ của môi trường hay không. Các phương pháp sử dụng mô hình được gọi là model-based, trong khi các phương pháp không cần mô hình được gọi là model-free. Sơ đồ phân loại chi tiết được trình bày trong Hình 2-2.



Hình 2-2. Các phương pháp theo mô hình môi trường

2.5.8.1. Quy hoạch động

Quy hoạch động (Dynamic Programming - DP) là đại diện tiêu biểu của nhóm model-based. Phương pháp này khai thác cấu trúc đệ quy của phương trình Bellman để tính toán hàm giá trị mà không cần tác nhân tương tác thực với môi trường.

Policy Iteration luân phiên giữa hai bước. Bước đánh giá chính sách (policy evaluation) tính hàm giá trị $v_{\pi}(s)$ cho chính sách hiện tại bằng cách giải lập hệ phương trình Bellman:

$$v_{k+1}(s) = \sum_a \pi(a | s) \sum_{s',r} p(s', r | s, a) [r + \gamma v_k(s')] \quad (2-25)$$

Bước cải thiện chính sách (policy improvement) cập nhật chính sách bằng phép chọn tham lam theo hàm giá trị vừa tính:

$$\pi'(s) = \operatorname{argmax}_a \sum_{s',r} p(s', r | s, a) [r + \gamma v_{\pi}(s')] \quad (2-26)$$

Hai bước này lặp cho đến khi chính sách không thay đổi, tại đó chính sách hội tụ về chính sách tối ưu.

Value Iteration gộp hai bước trên thành một phép cập nhật duy nhất dựa trên phương trình Bellman tối ưu:

$$v_{k+1}(s) = \max_a \sum_{s',r} p(s', r | s, a) [r + \gamma v_k(s')] \quad (2-27)$$

Thuật toán lặp cho đến khi hàm giá trị hội tụ, sau đó suy ra chính sách tối ưu bằng một bước tham lam. Tuy nhiên, quy hoạch động đòi hỏi phải biết đầy đủ hàm động lực và duyệt toàn bộ không gian trạng thái. Trong phần lớn các bài toán thực tế, cả hai điều kiện này đều không thỏa mãn, dẫn đến nhu cầu

về các phương pháp model-free có thể học trực tiếp từ kinh nghiệm tương tác (Sutton & Barto, 2014, tr 73–90).

2.5.8.2. Monte Carlo

Monte Carlo là phương pháp model-free đầu tiên được trình bày, trong đó tác nhân ước lượng hàm giá trị bằng cách lấy trung bình lợi nhuận thực tế thu được từ nhiều quỹ đạo hoàn chỉnh. Tại mỗi trạng thái S_t trong một episode, tác nhân tính lợi nhuận chiết khấu từ bước đó đến cuối episode:

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1} \quad (2-28)$$

Ước lượng hàm giá trị được cập nhật bằng cách dịch chuyển về phía lợi nhuận quan sát:

$$V(S_t) \leftarrow V(S_t) + \alpha[G_t - V(S_t)] \quad (2-29)$$

Ưu điểm của Monte Carlo là ước lượng không chệch, vì G_t là mẫu trực tiếp của lợi nhuận kỳ vọng. Tuy nhiên, Monte Carlo có hai hạn chế quan trọng. Thứ nhất, do G_t là tổng của nhiều phần thưởng ngẫu nhiên dọc theo toàn bộ quỹ đạo, phương sai của ước lượng thường rất lớn, đặc biệt khi episode dài. Thứ hai, tác nhân phải chờ đến khi kết thúc episode mới có thể cập nhật, khiến phương pháp chỉ áp dụng được cho bài toán episodic và không thể học trực tuyến (Sutton & Barto, 2014, tr 91–117).

2.5.8.3. Temporal-Difference

Temporal-Difference (TD) khắc phục cả hai hạn chế của Monte Carlo bằng cách kết hợp ý tưởng học từ kinh nghiệm giống Monte Carlo với cập nhật bootstrapping dựa trên ước lượng hiện tại giống với quy hoạch động. Thay vì chờ đến cuối episode, TD cập nhật hàm giá trị tại mỗi bước thời gian. Quy tắc cập nhật cơ bản nhất, gọi là TD(0), có dạng:

$$V(S_t) \leftarrow V(S_t) + \alpha \delta_t \quad (2-30)$$

Trong đó đại lượng δ_t được gọi là sai số TD (TD error), đo mức chênh lệch giữa ước lượng hiện tại và mục tiêu bootstrapping. Được định nghĩa bởi công thức:

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t) \quad (2-31)$$

Trong đó R_{t+1} là phần thưởng nhận được sau khi thực hiện hành động tại bước t , γ là hệ số chiết khấu. Giá trị δ_t phản ánh mức độ tốt hay xấu của hành động vừa thực hiện so với kỳ vọng trung bình: khi $\delta_t > 0$, hành động mang lại kết quả tốt hơn dự đoán khi $\delta_t < 0$, hành động kém hơn dự đoán.

So với Monte Carlo, TD có phương sai thấp hơn vì chỉ dựa vào phần thưởng một bước, nhưng đổi lại ước lượng có thiên lệch do phụ thuộc vào chất

lượng xấp xỉ $V(S_{t+1})$ hiện tại. Trong thực tế, sự đánh đổi này thường có lợi và TD hội tụ nhanh hơn Monte Carlo trên nhiều bài toán,

Hai thuật toán TD tiêu biểu cho việc học hàm giá trị hành động là SARSA và Q-learning. SARSA là thuật toán on-policy, cập nhật $Q(S_t, A_t)$ dựa trên hành động A_{t+1} mà tác nhân thực sự chọn theo chính sách hiện tại:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)] \quad (2-32)$$

Tên gọi SARSA bắt nguồn từ bộ năm $(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$ được sử dụng trong mỗi lần cập nhật.

Q-learning là thuật toán off-policy, cập nhật theo giá trị lớn nhất có thể tại trạng thái kế tiếp bất kể hành động thực tế được chọn:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)] \quad (2-33)$$

Điểm khác biệt cốt lõi là Q-learning luôn hướng về chính sách tham lam tối ưu trong cập nhật, bất kể chính sách đang dùng để thu thập dữ liệu. Điều này cho phép tách biệt chính sách hành vi được dùng để khám phá khỏi chính sách mục tiêu đang được tối ưu.

2.5.9. Deep Reinforcement Learning


DRL hình thành từ sự kết hợp giữa RL và DL, với mục tiêu mở rộng khả năng học chính sách trong các môi trường có quan sát phức tạp và không gian trạng thái rất lớn. Trong các bài toán thực tế, không gian trạng thái thường có số chiều rất lớn hoặc liên tục. Ví dụ, trong giao dịch tiền mã hóa, trạng thái có thể bao gồm hàng chục chỉ báo kỹ thuật, giá, số dư tài khoản và vị thế hiện tại. Khi đó, việc lưu trữ hàm giá trị $v(s)$ hoặc $q(s, a)$ dưới dạng bảng trở nên bất khả thi cả về bộ nhớ lẫn khả năng tổng quát hóa sang các trạng thái chưa gặp (Arulkumaran và c.s., 2017, tr 1). Trong bối cảnh đó, DRL sử dụng mạng nơ-ron sâu như một bộ xấp xỉ hàm (function approximator) để biểu diễn các đại lượng cốt lõi của RL.

Vai trò của xấp xỉ hàm trong RL không phải là một bổ sung tùy chọn mà là một nhu cầu có tính cấu trúc khi không gian trạng thái lớn hoặc liên tục. Điểm then chốt là ta thay thế các hàm chưa biết như $v_\pi(s)$ hoặc $q_\pi(s, a)$ bằng các mô hình tham số hóa, thường là mạng nơ-ron với tham số ϕ và thay thế chính sách bằng một mô hình tham số hóa với tham số θ . Khi đó, ta có thể viết các dạng xấp xỉ điển hình là $V_\phi(s) \approx v_\pi(s)$, $Q_\phi(s, a) \approx q_\pi(s, a)$ và $\pi_\theta(a | s) \approx \pi^*(a | s)$. Từ góc nhìn tối ưu hóa, bài toán RL được chuyển thành bài toán học tham số sao cho các xấp xỉ này ngày càng phù hợp với dữ liệu trải nghiệm mà tác nhân thu thập được.

Trong RL truyền thống, các bộ xấp xỉ này thường là mô hình đơn giản như hàm tuyến tính hoặc cây quyết định. DRL thay thế các mô hình đơn giản bằng mạng nơ-ron sâu có nhiều tầng ẩn, nhờ đó có khả năng biểu diễn các mối quan hệ phi tuyến phức tạp trong dữ liệu chiều cao (Y. Li, 2018a, tr 21). Nhờ khả năng tự động trích xuất các biểu diễn đặc trưng phân cấp từ dữ liệu thô, ví dụ như ảnh pixel, tín hiệu cảm biến mà không cần thiết kế đặc trưng thủ công. DL đã cho phép RL mở rộng tới những bài toán trước đây không thể giải được, chẳng hạn như học chơi trò chơi điện tử trực tiếp từ ảnh pixel thô (Arulkumaran và c.s., 2017).

Bước ngoặt quan trọng đánh dấu sự ra đời của DRL là công trình Deep Q-Network (DQN) của Mnih và cộng sự (2015), trong đó một mạng nơ-ron tích chập được huấn luyện để xấp xỉ hàm giá trị hành động $Q(s, a)$ trực tiếp từ ảnh pixel thô của trò chơi Atari 2600. DQN đạt hiệu suất ngang hoặc vượt con người trên nhiều trò chơi, chứng minh rằng một kiến trúc và thuật toán duy nhất có thể học được chính sách điều khiển hiệu quả từ đầu vào cảm biến chiều cao mà không cần thiết kế đặc trưng cho từng bài toán. DRL còn đạt được những kết quả vượt trội trên nhiều lĩnh vực, bao gồm trò chơi, robot, xử lý ngôn ngữ tự nhiên, tài chính, y tế, và giao thông thông minh (Y. Li, 2018a, tr 75–102).

Trên phương diện phương pháp, DRL thường được phân loại theo đối tượng tối ưu hóa chính, bao gồm nhóm phương pháp value-based (dựa trên giá trị), nhóm policy-based (dựa trên chính sách) và nhóm lai Actor-Critic được trình bày như Hình 2-3.



Hình 2-3. Phân loại theo đối tượng tối ưu

Các khảo sát hệ thống hóa rằng DRL đã trở thành một chủ đề rất phổ biến và được áp dụng rộng rãi, đồng thời phân loại thuật toán theo các hướng như mô hình hóa hay phi mô hình hóa, và các biến thể nâng cao. Với nhóm dựa trên giá trị, tác nhân học một xấp xỉ $Q_\phi(s, a)$, sau đó suy ra chính sách thông qua nguyên lý tham lam theo $a = \operatorname{argmax}_a Q_\phi(s, a)$. Hướng tiếp cận này phù hợp khi không gian hành động rời rạc và nhỏ, bởi phép cực đại hóa trên tập hành

động có thể thực hiện trực tiếp. Ngược lại, với nhóm dựa trên chính sách, tác nhân mô hình hóa trực tiếp $\pi_{\theta}(a | s)$ và tối ưu hóa một mục tiêu hiệu suất thông qua gradient, nhờ đó xử lý tự nhiên các hành động liên tục và chính sách ngẫu nhiên. Tuy nhiên, ước lượng gradient thuần túy thường có phương sai lớn, dẫn tới quá trình học thiếu ổn định. Nhóm lai Actor-Critic xuất hiện với một mô hình học chính sách đóng vai trò Actor, trong khi một mô hình học hàm giá trị đóng vai trò Critic để cung cấp tín hiệu đánh giá và giảm phương sai trong cập nhật.

Đối với bài toán giao dịch tài chính nói chung và giao dịch tiền mã hóa nói riêng, DRL có sức hấp dẫn vì môi trường vừa có độ nhiễu cao vừa có trạng thái đa biến, trong đó quan sát thường gồm các chuỗi thời gian giá, khối lượng, chỉ báo kỹ thuật, cùng các thông tin danh mục như tiền mặt, vị thế và giá trị tài sản ròng. Những đặc trưng này làm cho không gian trạng thái có số chiều lớn và biến động theo thời gian; do đó, cách tiếp cận dựa trên xấp xỉ hàm bằng mạng nơ-ron trở thành lựa chọn tự nhiên. Đồng thời, việc dùng chính sách ngẫu nhiên và các thuật toán Actor-Critic cho phép mô hình hóa trực tiếp phân phối hành động, điều có thể hữu ích khi cân cân bằng giữa thăm dò và khai thác trong một thị trường không chắc chắn.

2.5.10. Phương pháp Policy Gradient

Các phương pháp value-based học hàm giá trị hành động rồi suy ra chính sách, chẳng hạn chọn hành động có giá trị Q lớn nhất. Sutton và Barto (2014, tr 321–338) chỉ ra rằng hướng tiếp cận này có một số hạn chế bản chất. Thứ nhất, chính sách suy ra từ hàm giá trị luôn là tất định, trong khi có những bài toán mà chính sách tối ưu thực chất lại là ngẫu nhiên, ví dụ các bài toán có quan sát không đầy đủ hoặc bài toán đối kháng. Thứ hai, một thay đổi nhỏ trong ước lượng hàm giá trị có thể khiến hành động tham lam nhảy sang hành động hoàn toàn khác, gây bất ổn trong quá trình học. Phương pháp policy gradient khắc phục những hạn chế này bằng cách tham số hoá trực tiếp chính sách $\pi_{\theta}(a | s)$ và cập nhật tham số θ theo hướng gradient của một thước đo hiệu suất, mà không cần suy chính sách từ hàm giá trị.

Sutton và Barto (2014) định nghĩa thước đo hiệu suất $J(\theta)$ trong bài toán episodic là giá trị của trạng thái khởi đầu dưới chính sách π_{θ} :

$$J(\theta) = v_{\pi_{\theta}}(s_0) \quad (2-34)$$

Trong đó $v_{\pi_{\theta}}(s_0)$ là hàm giá trị trạng thái tại s_0 , được xác định bởi tham số θ . Mục tiêu của huấn luyện là tìm θ cực đại hoá $J(\theta)$ bằng gradient ascent:

$$\theta_{t+1} = \theta_t + \alpha \nabla_{\theta} \widehat{J(\theta_t)} \quad (2-35)$$

Trong đó $\widehat{\nabla_{\theta} J}$ là ước lượng ngẫu nhiên của gradient thực và α là tốc độ học. Vấn đề cốt lõi là làm thế nào để ước lượng gradient này khi cả phần thưởng lẫn phân phối trạng thái đều phụ thuộc vào θ thông qua chính sách.

Định lý Policy Gradient, được Sutton và Barto (2014) giải quyết vấn đề này. Định lý phát biểu rằng gradient của hàm mục tiêu có thể viết dưới dạng:

$$\nabla_{\theta} J(\theta) \propto \sum_s \mu(s) \sum_a q_{\pi}(s, a) \nabla_{\theta} \pi_{\theta}(a|s) \quad (2-36)$$

Trong đó $\mu(s)$ là phân phối on-policy dưới chính sách π_{θ} , và $q_{\pi}(s, a)$ là hàm giá trị hành động. Kết quả đáng chú ý ở đây là gradient của hàm mục tiêu không chứa đạo hàm của phân phối trạng thái $\mu(s)$ theo θ , mặc dù $\mu(s)$ phụ thuộc vào chính sách và do đó phụ thuộc vào θ . Đây là điểm then chốt giúp gradient có thể được ước lượng từ kinh nghiệm tương tác mà không cần biết mô hình của môi trường.

Bằng cách sử dụng thủ thuật log-derivative ta có thể viết lại phương trình trên dưới dạng giá trị kỳ vọng:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi}[q_{\pi}(S_t, A_t) \nabla_{\theta} \ln \pi_{\theta}(A_t | S_t)] \quad (2-37)$$

Thuật toán REINFORCE là hiện thực hoá trực tiếp của công thức trên. Trong REINFORCE, $q_{\pi}(S_t, A_t)$ được thay bằng tổng phần thưởng chiết khấu thực tế $G_t = \sum_{k=0}^{T-t} \gamma^k r_{t+k}$ thu được từ quỹ đạo đã trải qua. Quy tắc cập nhật là:

$$\theta \leftarrow \theta + \alpha \gamma^t G_t \nabla_{\theta} \ln \pi_{\theta}(A_t | S_t) \quad (2-38)$$

2.5.11. Phương pháp Actor-Critic

Thuật toán REINFORCE ước lượng policy gradient bằng tổng phần thưởng chiết khấu thực tế G_t thu được từ toàn bộ quỹ đạo. Do G_t là ước lượng Monte Carlo, giá trị này có phương sai rất lớn giữa các quỹ đạo khác nhau, khiến quá trình hội tụ chậm và thiếu ổn định (Sutton & Barto, 2014, tr 326–329). Phương pháp Actor-Critic ra đời nhằm khắc phục hạn chế này bằng cách kết hợp hai thành phần: một mạng chính sách đóng vai trò Actor và một mạng hàm giá trị đóng vai trò Critic.

Thành phần Actor duy trì chính sách tham số hóa $\pi_{\theta}(a | s)$, có nhiệm vụ lựa chọn hành động cho tác nhân. Thành phần Critic duy trì một ước lượng hàm giá trị, thường là hàm giá trị trạng thái $V_{\phi}(s)$ với tham số ϕ , có nhiệm vụ đánh giá chất lượng của hành động mà Actor vừa thực hiện. Thay vì chờ đến cuối quỹ đạo để tính G_t như REINFORCE, Critic cung cấp tín hiệu đánh giá ngay tại mỗi bước thời gian, cho phép Actor cập nhật tham số liên tục trong quá trình tương tác. Tín hiệu đánh giá mà Critic cung cấp cho Actor chính là sai số TD đã được giới thiệu tại công thức (2-31). Tuy nhiên, trong Actor-Critic, hàm

giá trị trạng thái được xấp xỉ bởi mạng thần kinh Critic với bộ tham số ϕ , ký hiệu là V_ϕ . Khi đó, sai số TD được tính toán trực tiếp dựa trên mạng Critic như sau:

$$\delta_t = R_{t+1} + \gamma V_\phi(S_{t+1}) - V_\phi(S_t) \quad (2-39)$$

Quy tắc cập nhật tham số của Actor và Critic tại mỗi bước thời gian như sau. Critic cập nhật tham số w theo hướng giảm sai số đánh giá:

$$\phi \leftarrow \phi + \alpha_\phi \delta_t \nabla_\phi V_\phi(S_t) \quad (2-40)$$

Actor cập nhật tham số θ theo hướng policy gradient, sử dụng δ_t thay cho G_t :

$$\theta \leftarrow \theta + \alpha_\theta \gamma^t \delta_t \nabla_\theta \ln \pi_\theta(A_t | S_t) \quad (2-41)$$

Trong đó α_ϕ và α_θ lần lượt là tốc độ học của Critic và Actor. Việc thay G_t bằng δ_t trong công thức cập nhật Actor chính là cơ chế giảm phương sai cốt lõi của kiến trúc Actor-Critic (Sutton & Barto, 2014, tr 331–332).

So sánh với REINFORCE, phương pháp Actor-Critic mang lại hai lợi thế chính. Thứ nhất, nhờ cập nhật tại từng bước thời gian thay vì cuối quỹ đạo, Actor-Critic có thể học trực tuyến và hội tụ nhanh hơn trong thực tế. Thứ hai, phương sai thấp hơn giúp quá trình huấn luyện ổn định hơn, đặc biệt quan trọng trong các bài toán có quỹ đạo dài hoặc phần thưởng biến động lớn như giao dịch tài chính.

2.5.12. Generalized Advantage Estimation

Trong các phương pháp policy gradient, chất lượng ước lượng hàm lợi thế $\hat{A}_t$ ảnh hưởng trực tiếp đến tốc độ hội tụ và độ ổn định của quá trình huấn luyện. Phương pháp Monte Carlo ước lượng lợi thế từ tổng phần thưởng thực tế nên không chệch (low bias), nhưng phương sai cao do tích lũy ngẫu nhiên qua nhiều bước. Ngược lại, phương pháp TD chỉ dùng phần thưởng một bước kết hợp với hàm giá trị ước lượng nên phương sai thấp, nhưng chệch khi hàm giá trị chưa chính xác. Schulman và cs. (2018) đề xuất Generalized Advantage Estimation (GAE) nhằm tổng quát hóa hai phương pháp trên, cho phép điều chỉnh linh hoạt sự đánh đổi giữa bias và variance thông qua một tham số duy nhất. GAE ước lượng hàm lợi thế bằng tổng có trọng số suy giảm theo cấp số nhân của các bước sai số chênh lệch:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{T-t} (\gamma \lambda)^l \delta_{t+l} \quad (2-42)$$

Trong đó, δ_{t+l} là sai số TD tại bước thời gian $t + l$, được mở rộng một cách tổng quát hóa từ định nghĩa tại công thức (2-31) như sau:

$$\delta_{t+l} = R_{t+l+1} + \gamma V(S_{t+l+1}) - V(S_{t+l}) \quad (2-43)$$

Tham $\lambda \in [0,1]$ là tham số điều khiển mức độ đánh đổi giữa bias và variance.

Khi $\lambda = 0$, $\hat{A}_t = \delta_t$ tương đương ước lượng TD một bước với δ_t được định nghĩa ở công thức (2-31). Phương sai thấp nhưng độ chệch cao do phụ thuộc hoàn toàn vào độ chính xác của $V(s_t)$.

Khi $\lambda = 1$, $\hat{A}_t = \sum_{l=0}^{T-t} \gamma^l r_{t+l} - V(s_t)$, tương đương ước lượng Monte Carlo. Độ chệch thấp nhưng phương sai cao.

Trong thực nghiệm, λ thường được đặt trong khoảng 0.9 đến 0.99 (Schulman và c.s., 2018), giúp GAE kế thừa ưu điểm của cả hai phương pháp: duy trì phương sai ở mức chấp nhận được trong khi giảm thiểu độ chệch. Nhờ đó, PPO sử dụng GAE để ước lượng $\hat{A}_t$ trong hàm mục tiêu, đảm bảo quá trình cập nhật chính sách vừa ổn định vừa hiệu quả.

2.5.13. Proximal Policy Optimization

PPO đã được John Schulman và cs. (2017) đề xuất, thuật toán này được biết đến với khả năng mở rộng tốt, hiệu quả về dữ liệu, bền vững và là một trong những thuật toán phù hợp nhất cho các miền ứng dụng có tính ngẫu nhiên cao. Ngoài ra, nó là 1 thuật toán có độ ổn định rất cao khi huấn luyện.

PPO thuộc họ các phương pháp policy gradient cho DRL, chủ yếu là các phương pháp on-policy, tức tìm hành động tiếp theo dựa trên chính sách hiện tại. Các phương pháp policy gradient sử dụng Policy Loss Function:

$$L^{PG}(\theta) = \mathbb{E}_t[\log \pi_\theta(a_t | s_t) \hat{A}_t] \quad (2-44)$$

Trong đó $\mathbb{E}_t[\log \pi_\theta(a_t | s_t)]$ biểu diễn log xác suất kỳ vọng của việc thực hiện hành động a tại trạng thái s , và $\hat{A}_t$ là hàm lợi thế ước lượng, cung cấp ước lượng giá trị của hành động hiện tại so với trung bình tất cả các hành động khả thi tại trạng thái s .

PPO đảm bảo tính ổn định của quá trình cập nhật chính sách bằng cách kiểm soát trực tiếp độ lớn bước gradient ascent. Hàm mục tiêu được viết lại dưới dạng:

$$L^{CPI}(\theta) = \mathbb{E}_t \left[\frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{old}}(a_t | s_t)} \hat{A}_t \right] = \mathbb{E}_t[r_t(\theta) \hat{A}_t] \quad (2-45)$$

Trong đó $\log \pi_\theta(a_t | s_t)$ được thay thế bởi $r_t(\theta)$, tỷ số giữa xác suất của hành động dưới chính sách hiện tại và xác suất dưới chính sách trước đó được xác định bởi công thức:

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{old}}(a_t | s_t)} \quad (2-46)$$

Khi $r_t(\theta) > 1$, hành động có xác suất cao hơn trong chính sách hiện tại so với chính sách trước. Khi $0 < r_t(\theta) < 1$, hành động có xác suất cao hơn trong chính sách trước. Khi $r_t(\theta)$ lệch xa khỏi 1, một bước cập nhật chính sách quá lớn sẽ được thực hiện.

Để tránh việc cập nhật quá lớn và phá hỏng policy hiện tại thì hàm mục tiêu được sửa đổi lại, thêm vào cơ chế phạt các giá trị $r_t(\theta)$ nằm ngoài khoảng $[1 - \varepsilon, 1 + \varepsilon]$, được xác định bởi công thức:

$$L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\widehat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon)\widehat{A}_t)] \quad (2-47)$$

PPO thường sử dụng kiến trúc Actor-Critic. Do đó, hàm mục tiêu toàn cục của mô hình phải tối ưu hóa đồng thời mạng chính sách và mạng đánh giá giá trị. Hàm mục tiêu tổng quát được định nghĩa là:

$$L_t^{CLIP+VF+S}(\theta) = \mathbb{E}_t[L_t^{CLIP}(\theta) - c_1 L_t^{VF}(\theta) + c_2 S[\pi_\theta](s_t)] \quad (2-48)$$

Trong đó, $L_t^{VF}(\theta)$ là bình phương sai số của mạng giá trị, đo lường khoảng cách giữa giá trị dự đoán và lợi nhuận thực tế. Cụ thể, hàm này được định nghĩa bởi công thức:

$$L_t^{VF}(\theta) = (V_\theta(s_t) - \widehat{R}_t)^2 \quad (2-49)$$

Trong đó $\widehat{R}_t$ là giá trị mục tiêu ở mỗi bước. $S[\pi_\theta](s_t)$ là entropy bonus, khuyến khích chính sách duy trì phân bố xác suất đều hơn giữa các hành động, tránh hội tụ sớm vào một chiến lược chưa tối ưu. Điều này đặc biệt quan trọng trong các môi trường có tính ngẫu nhiên cao, nơi tác nhân cần duy trì khả năng khám phá. Các siêu tham số c_1, c_2 được sử dụng để cân bằng mức độ đóng góp của hàm giá trị và mức độ khám phá vào tổng thể quá trình học.

Bảng 2-1. Mã giả thuật toán PPO

Thuật toán PPO	
Input: Policy network π_θ , Value network V_ϕ , clipping parameter ε , discount factor γ , GAE parameter λ , số epoch K , mini-batch size M , số bước rollout T	
Output: Policy tối ưu π_{θ^*}	
1.	Khởi tạo tham số θ và ϕ ngẫu nhiên
2.	Cập nhật trọng số mạng cũ: $\theta_{old} \leftarrow \theta$ và $\phi_{old} \leftarrow \phi$
3.	for iteration = 1, 2, ... do
4.	Chạy chính sách π_θ trong môi trường để thu thập T bước quỹ đạo $\mathcal{D} = \{S_t, A_t, R_{t+1}\}_{t=1}^T$
5.	Tính TD Error cho mỗi bước $t \in \{1, \dots, T\}$: $\delta_t = R_{t+1} + \gamma V_{\phi_{old}}(S_{t+1}) - V_{\phi_{old}}(S_t)$
6.	Ước lượng Advantage $\widehat{A}_t$ bằng GAE cho mọi t : $\widehat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}$

-
7. Tính giá trị mục tiêu $\hat{R}_t$ cho mỗi timestep:

$$\hat{R}_t = \hat{A}_t + V_{\phi_{old}}(s_t)$$
 8. **for** epoch = 1, ..., K **do**
 9. Lấy mini-batch ngẫu nhiên từ $\mathcal{D}$ có kích thước M
 10. **for** mỗi mini-batch **do**
 11. Tính tỉ số: $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$
 12. Tính hàm mục tiêu surrogate:

$$L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)]$$
 13. Tính giá trị Loss của Critic:

$$L^{VF}(\phi) = \mathbb{E}_t[(V_{\phi}(s_t) - \hat{R}_t)^2]$$
 14. Tổng hợp hàm mất mát:

$$\mathcal{L}^{Loss}(\theta, \phi) = \mathbb{E}_t[-L^{CLIP}(\theta) + c_1 L^{VF}(\phi) - c_2 H[\pi_{\theta}]]$$
 15. Cập nhật θ và ϕ bằng gradient descent để cực tiểu hóa $\mathcal{L}^{Loss}(\theta, \phi)$
 16. **end for**
 17. **end for**
 18. Cập nhật lại tham số cũ: $\theta_{old} \leftarrow \theta$
 19. Cập nhật lại tham số cũ: $\phi_{old} \leftarrow \phi$
 20. **end for**
 21. **return** π_{θ}
-

Mã giả cách hoạt động của thuật toán PPO được thể hiện ở Bảng 2-1.

2.5.14. Các thước đo đánh giá hiệu suất giao dịch

Để đánh giá hiệu quả và mức độ an toàn của chiến lược giao dịch do tác nhân học được, nghiên cứu sử dụng một hệ thống các thước đo tài chính tiêu chuẩn. Các chỉ số này cho phép so sánh hiệu suất của tác nhân với một chiến lược cơ sở, từ đó xác định mức độ vượt trội của mô hình không chỉ về lợi nhuận mà còn về khả năng kiểm soát rủi ro. Dựa trên cách tiếp cận của Filos (2019), các đại lượng đánh giá chính được định nghĩa như sau. Ta có simple return của 1 loại tài sản được định nghĩa:

$$r_t = \frac{p_t - p_{t-1}}{p_{t-1}} = \frac{p_t}{p_{t-1}} - 1 \quad (2-50)$$

Simple return là một trong những thước đo được sử dụng phổ biến trong phân tích tài chính vì nó trực tiếp phản ánh mức tăng hoặc giảm tương đối của tài sản trong một chu kỳ quan sát.

2.5.14.1. Chiến lược Buy and Hold (B&H)

Trong nghiên cứu này, chiến lược Buy and Hold (B&H) được sử dụng làm chiến lược cơ sở. Đây là chiến lược thụ động, trong đó toàn bộ vốn ban đầu được dùng để mua tài sản tại thời điểm đầu của giai đoạn kiểm thử và sau đó được nắm giữ liên tục cho đến thời điểm kết thúc mà không thực hiện thêm bất

kỳ giao dịch nào. B&H thường được dùng làm mốc so sánh để đánh giá xem chiến lược giao dịch chủ động có thực sự tạo ra giá trị gia tăng so với việc nắm giữ đơn thuần hay không.

2.5.14.2. Lợi nhuận tích lũy

Lợi nhuận tích lũy (CR) là thước đo phản ánh tổng mức sinh lời của danh mục trong toàn bộ giai đoạn xét đến. Nếu ký hiệu p_t là giá tại thời điểm bắt đầu giai đoạn đánh giá và p_T là giá tại thời điểm kết thúc, lợi nhuận tích lũy từ t đến T được xác định bởi:

$$r_{t \rightarrow T} = \frac{p_T}{p_t} - 1 = \prod_{i=t+1}^T \frac{p_i}{p_{i-1}} - 1 \in \mathbb{R} \quad (2-51)$$

Chỉ số này cho biết mức tăng trưởng tổng thể của tài sản hoặc danh mục đầu tư sau toàn bộ chuỗi giao dịch, và là một trong những đại lượng cơ bản nhất khi đánh giá hiệu suất đầu tư.

2.5.14.3. Maximum Drawdown

MDD là một trong những chỉ số quan trọng để đánh giá rủi ro, đặc biệt trong thị trường biến động mạnh như tài sản số. MDD đo lường tỷ lệ sụt giảm giá trị tài sản lớn nhất từ một đỉnh xuống một đáy liền kề trước khi một đỉnh mới được thiết lập. Để xác định MDD, trước tiên cần định nghĩa giá trị đỉnh tích lũy tại thời điểm t :

$$M_t = \max_{\tau \in [0, t]} V_\tau \quad (2-52)$$

Trong đó V_τ là tổng giá trị tài sản tại thời điểm τ . Giá trị M_t ghi nhận mức cao nhất mà danh mục đã từng đạt được tính đến thời điểm t .

Tại mỗi thời điểm t , mức sụt giảm được định nghĩa là tỷ lệ giảm giá trị so với đỉnh tích lũy:

$$D_t = \frac{M_t - V_t}{M_t} \quad (2-53)$$

Maximum Drawdown là giá trị lớn nhất của Drawdown trên toàn bộ chu kỳ $[0, T]$:

$$\text{MDD} = \max_{t \in [0, T]} D_t \quad (2-54)$$

Giá trị MDD càng nhỏ cho thấy chiến lược kiểm soát rủi ro càng tốt, tức là danh mục không bao giờ sụt giảm quá sâu so với đỉnh trước đó. Trong thị trường tiền mã hóa, nơi giá có thể biến động hàng chục phần trăm trong một phiên giao dịch, MDD là thước đo không thể thiếu để đánh giá khả năng bảo toàn vốn của tác nhân.

2.5.14.4. Tỷ lệ Sharpe

Tỷ lệ Sharpe là thước đo hiệu suất đã điều chỉnh theo rủi ro, được dùng rộng rãi để so sánh chất lượng của các chiến lược, danh mục có mức biến động khác nhau. Chỉ số này đo lường xem một chiến lược giao dịch mang lại bao nhiêu đơn vị lợi nhuận vượt trội cho mỗi một đơn vị rủi ro mà nó phải gánh chịu. Được xác định bởi công thức:

$$S = \frac{\mathbb{E}[R_a - R_b]}{\sigma_a} \sqrt{N} \quad (2-55)$$

Trong đó $\mathbb{E}[R_a - R_b]$ là giá trị kỳ vọng của mức chênh lệch giữa tỷ suất sinh lời của chiến lược a và tỷ suất sinh lời của chiến lược cơ sở hoặc tài sản phi rủi ro b . Ký hiệu σ_a độ lệch chuẩn của tỷ suất sinh lời chiến lược a , đại diện cho mức độ biến động hay tổng rủi ro của chiến lược. Trong thực tế, để so sánh giữa các chiến lược có tần suất giao dịch khác nhau, tỷ lệ Sharpe thường được chuẩn hóa về đơn vị năm (annualized) bằng cách nhân với $\sqrt{N}$, trong đó N là số chu kỳ quan sát trong một năm.

Trong bối cảnh đánh giá mô hình giao dịch tài sản số, tỷ lệ Sharpe càng cao chứng tỏ tác nhân không chỉ tìm kiếm được lợi nhuận mà còn duy trì được sự ổn định, né tránh các rủi ro không cần thiết. Ngược lại, một chiến lược có tỷ lệ Sharpe thấp đồng nghĩa với việc mức lợi nhuận thu được không tương xứng với biên độ rủi ro quá lớn mà hệ thống đã phải đối mặt.

2.5.15. Hàm kích hoạt GeLU

Hàm kích hoạt là thành phần then chốt quyết định khả năng biểu diễn phi tuyến của mạng nơ-ron sâu. Trong nghiên cứu này, hàm kích hoạt Gaussian Error Linear Unit (GeLU) được lựa chọn cho các lớp ẩn của mạng Actor và Critic. GeLU được đề xuất bởi Hendrycks và Gimpel (2023), với ý tưởng kết hợp phép biến đổi tất định với cơ chế công ngẫu nhiên lấy cảm hứng từ Dropout và Zoneout nhằm tạo ra một hàm phi tuyến vừa có tính chính quy hóa nội tại, vừa tôn trọng giá trị đầu vào của mỗi nơ-ron.

Về mặt toán học, GeLU được định nghĩa là tích của đầu vào x với hàm phân phối tích lũy (CDF) của phân phối chuẩn tắc:

$$\text{GeLU}(x) = x\Phi(x) \quad (2-56)$$

Trong đó $\Phi(x) = P(X \leq x)$ với $X \sim \mathcal{N}(0,1)$. Trong thực hành, biểu thức xấp xỉ thường được sử dụng để tăng tốc tính toán:

$$\text{GeLU}(x) \approx 0,5x \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + 0,044715x^3) \right) \right) \quad (2-57)$$

Khác với hàm kích hoạt ReLU có ngưỡng cứng tại 0, triệt tiêu hoàn toàn các giá trị âm, GeLU thực hiện phép "cổng hóa" mềm (soft gating) theo phân phối xác suất, cho phép một phần tín hiệu âm đi qua tùy thuộc vào độ lớn của đầu vào. GeLU có đạo hàm trơn trên toàn miền, giúp gradient được truyền ổn định hơn trong quá trình lan truyền ngược, tránh hiện tượng neuron chết thường gặp ở ReLU. GeLU còn có tính phi đơn điệu ở vùng âm giúp mạng có khả năng biểu diễn phong phú hơn. Các đánh giá thực nghiệm cho thấy GeLU đạt hiệu suất vượt trội so với ReLU và ELU trên nhiều tác vụ khác nhau, bao gồm phân loại và mô hình ngôn ngữ.

2.5.16. Bộ tối ưu AdamW

Adam (Adaptive Moment Estimation) là một trong những bộ tối ưu được sử dụng phổ biến nhất trong DL, kết hợp ước lượng moment bậc nhất (trung bình động của gradient) và moment bậc hai (trung bình động của bình phương gradient) để điều chỉnh tốc độ học riêng cho từng tham số. Tuy nhiên, Loshchilov và Hutter (2019) chỉ ra rằng cách triển khai chính quy hóa L_2 trong Adam, vốn thường bị gọi là "weight decay" thực chất không tương đương với weight decay truyền thống như trong SGD. Cụ thể, trong Adam chuẩn, gradient của thành phần phạt L_2 bị chia cho ước lượng moment bậc hai, khiến mức độ suy giảm trọng số phụ thuộc vào lịch sử gradient, các tham số có gradient lớn sẽ bị suy giảm ít hơn dự kiến, và ngược lại. Để khắc phục vấn đề này, AdamW tách biệt (decouple) bước suy giảm trọng số khỏi bước cập nhật theo gradient:

$$\theta_{t+1} = \theta_t - \alpha \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda \theta_t \right) \quad (2-58)$$

Trong đó $\hat{m}_t$ và $\hat{v}_t$ lần lượt là ước lượng moment bậc nhất và bậc hai đã hiệu chỉnh độ lệch, α là tốc độ học, ϵ là hằng số ổn định số, và λ là hệ số weight decay. Nhờ việc tách biệt này, mức độ suy giảm trọng số trở nên đồng đều và không bị biến dạng bởi cơ chế thích ứng tốc độ học, giúp cải thiện đáng kể khả năng tổng quát hóa của mô hình.

2.5.17. Long Short-Term Memory

Long Short-Term Memory (LSTM) là một biến thể của mạng hồi tiếp được đề xuất nhằm khắc phục hạn chế của các mạng nơ-ron hồi tiếp truyền thống trong việc ghi nhớ thông tin trên các chuỗi dữ liệu dài. LSTM được thiết

kể với cấu trúc bộ nhớ đặc biệt, cho phép mô hình duy trì hoặc loại bỏ thông tin một cách có chọn lọc thông qua các cổng điều khiển. Nhờ đó, LSTM có khả năng học và khai thác các mối quan hệ phụ thuộc dài hạn trong dữ liệu tốt hơn so với các kiến trúc hồi tiếp cơ bản. Kiến trúc của LSTM được minh họa ở Hình 2-4.

Theo nghiên cứu của Chung, Gulcehre, Cho và Bengio (2014), cấu trúc của LSTM thường bao gồm ba cổng chính là cổng quên, cổng vào và cổng ra. Khác với khối nơ-ron hồi tiếp truyền thống, mỗi khối LSTM thứ j duy trì một trạng thái nhớ $c_t^{(j)}$ tại thời điểm t . Đầu ra $h_t^{(j)}$ của mạng có dạng:

$$h_t^{(j)} = o_t^{(j)} \tanh(c_t^{(j)}) \quad (2-59)$$

Trong đó, $o_t^{(j)}$ là cổng ra (output gate) có nhiệm vụ điều tiết lượng thông tin từ bộ nhớ được xuất ra ngoài. Cổng ra được tính bằng:

$$o_t^{(j)} = \sigma(W_o x_t + U_o h_{t-1} + V_o c_t)^{(j)} \quad (2-60)$$

Với σ là hàm sigmoid và là V_o một ma trận đường chéo. Trạng thái nhớ $c_t^{(j)}$ được cập nhật thông qua việc giảm đi một phần bộ nhớ hiện tại và thêm vào một nội dung bộ nhớ mới $\tilde{c}_t^{(j)}$:

$$c_t^{(j)} = f_t^{(j)} c_{t-1}^{(j)} + i_t^{(j)} \tilde{c}_t^{(j)} \quad (2-61)$$

Nội dung bộ nhớ mới được tính toán theo phương trình:


$$\tilde{c}_t^{(j)} = \tanh(W_c x_t + U_c h_{t-1})^{(j)} \quad (2-62)$$

Mức độ mà bộ nhớ hiện tại bị lãng quên được điều khiển bởi cổng quên (forget gate) $f_t^{(j)}$, và mức độ mà nội dung bộ nhớ mới được thêm vào ô nhớ được điều khiển bởi cổng vào (input gate) $i_t^{(j)}$. Các cổng này được xác định như sau:

$$f_t^{(j)} = \sigma(W_f x_t + U_f h_{t-1} + V_f c_{t-1})^{(j)} \quad (2-63)$$

$$i_t^{(j)} = \sigma(W_i x_t + U_i h_{t-1} + V_i c_{t-1})^{(j)} \quad (2-64)$$

Với V_f và V_i là các ma trận đường chéo.




Hình 2-4. Long Short-Term Memory. Nguồn: Chung và c.s (2014)

Trong các bài toán phân tích chuỗi thời gian, LSTM thường được sử dụng để mô hình hóa các quan hệ tuần tự giữa các quan sát liên tiếp. Với đặc điểm có khả năng ghi nhớ ngữ cảnh trong quá khứ, LSTM đặc biệt phù hợp với các dữ liệu có tính động và phụ thuộc mạnh vào diễn biến trước đó. Trong nghiên cứu này, LSTM được sử dụng như một bộ trích xuất đặc trưng nhằm khai thác thông tin theo chuỗi từ dữ liệu đầu vào.

2.5.18. Gated Recurrent Unit

Gated Recurrent Neural Networks (GRU) là một biến thể khác của mạng hồi tiếp có cơ chế cổng, được đề xuất nhằm đơn giản hóa cấu trúc của LSTM nhưng vẫn duy trì khả năng học các phụ thuộc dài hạn trong dữ liệu chuỗi. So với LSTM, GRU có cấu trúc gọn hơn nhờ hợp nhất một số thành phần bộ nhớ và cổng điều khiển, do đó thường có số lượng tham số ít hơn và chi phí tính toán thấp hơn. Hình 2-5 minh họa kiến trúc khối GRU.



Hình 2-5. Gated Recurrent Unit. Nguồn: Chung và c.s (2014)

Cấu trúc của GRU gồm hai cổng chính là cổng cập nhật và cổng đặt lại. Cổng cập nhật quyết định mức độ thông tin quá khứ cần được giữ lại trong trạng thái hiện tại, trong khi cổng đặt lại điều tiết mức độ ảnh hưởng của thông tin cũ khi tạo ra trạng thái mới (Chung và c.s., 2014). Nhờ cơ chế này, GRU vừa có khả năng ghi nhớ thông tin quan trọng trong chuỗi dữ liệu, vừa giảm bớt độ phức tạp của mô hình trong quá trình huấn luyện.

Giá trị kích hoạt $h_t^{(j)}$ của khối GRU tại thời điểm t là kết quả nội suy tuyến tính giữa giá trị kích hoạt ở bước thời gian trước đó $h_{t-1}^{(j)}$ và giá trị kích hoạt ứng viên $\tilde{h}_t^{(j)}$:

$$h_t^{(j)} = (1 - z_t^{(j)})h_{t-1}^{(j)} + z_t^{(j)}\tilde{h}_t^{(j)} \quad (2-65)$$

Trong đó, cổng cập nhật (update gate) $z_t^{(j)}$ quyết định mức độ mà khối nơ-ron sẽ cập nhật giá trị kích hoạt của nó. Cổng cập nhật được xác định bởi công thức:

$$z_t^{(j)} = \sigma(W_z x_t + U_z h_{t-1}^{(j)})^{(j)} \quad (2-66)$$

Quá trình lấy tổng tuyến tính giữa trạng thái hiện tại và trạng thái mới được tính toán này hoàn toàn tương tự như cơ chế của khối LSTM. Mặc dù vậy, GRU không có cơ chế để kiểm soát mức độ bộc lộ trạng thái; thay vào đó, khối này bộc lộ toàn bộ trạng thái của nó tại mỗi thời điểm.

Giá trị kích hoạt ứng viên $\tilde{h}_t^{(j)}$ được tính toán tương tự như khối hồi tiếp truyền thống:

$$\tilde{h}_t^{(j)} = \tanh(W x_t + U(r_t \odot h_{t-1}^{(j)}))^{(j)} \quad (2-67)$$

Trong đó, r_t là tập hợp các cổng đặt lại (reset gates) và $\odot$ là ký hiệu của phép nhân từng phần tử. Khi cổng này giá trị tiến về 0, cổng khiến khối nơ-ron hoạt động như thể nó đang đọc ký hiệu đầu tiên của một chuỗi đầu vào, qua đó cho phép mô hình loại bỏ trạng thái đã được tính toán trước đó.

Cổng đặt lại $r_t^{(j)}$ được tính toán tương tự như cổng cập nhật:

$$r_t^{(j)} = \sigma(W_r x_t + U_r h_{t-1})^{(j)} \quad (2-68)$$

Do có thiết kế đơn giản hơn LSTM nhưng vẫn đảm bảo khả năng biểu diễn quan hệ thời gian, GRU thường được xem là một lựa chọn hiệu quả trong các bài toán chuỗi thời gian và dự báo. Trong nhiều trường hợp, GRU có thể đạt hiệu quả tương đương LSTM trong khi yêu cầu ít tài nguyên tính toán hơn. Trong nghiên cứu này, GRU cũng được sử dụng như một bộ trích xuất đặc trưng để đánh giá khả năng khai thác thông tin theo thời gian từ dữ liệu đầu vào.

2.5.19. Layer Normalization

Layer Normalization là một phương pháp được giới thiệu trong nghiên cứu của Ba, Kiros, & Hinton (2016) nhằm chuẩn hóa các kích hoạt trong mạng nơ-ron bằng cách tính trung bình và phương sai trên toàn bộ đầu vào của các nơ-ron trong cùng một lớp tại từng mẫu riêng lẻ. Khác với Batch Normalization, phương pháp này không phụ thuộc vào kích thước mini-batch và thực hiện cùng một phép biến đổi ở cả giai đoạn huấn luyện lẫn kiểm thử, do đó phù hợp hơn với các mô hình có cấu trúc tuần tự. Layer Normalization đặc biệt hiệu quả trong việc ổn định động học trạng thái ẩn của các mạng hồi tiếp, đồng thời góp phần cải thiện tốc độ hội tụ của mô hình trong quá trình huấn luyện. Về mặt tính toán, Layer Normalization được biểu diễn như sau:

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i, \sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2 \quad (2-69)$$


$$\text{LN}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \quad (2-70)$$

Trong đó, $x \in \mathbb{R}^d$ là vector đầu vào, μ và σ^2 lần lượt là trung bình và phương sai của các phần tử trong vector, ϵ là hằng số nhỏ dùng để tránh chia cho 0, còn γ và β là các tham số học được giúp mô hình điều chỉnh lại phân phối sau chuẩn hóa.

Chương 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1. MÔ HÌNH TỔNG QUÁT

Nhìn trên tổng thể, bài toán huấn luyện tác nhân giao dịch có thể được trừu tượng hóa thành một luồng pipeline liên tục. Quá trình này bắt đầu từ việc thu thập dữ liệu, trải qua các bước trích xuất đặc trưng để xây dựng môi trường, và cuối cùng là đưa vào vòng lặp huấn luyện DRL nhằm tìm ra mô hình hội tụ tối ưu nhất. Các giai đoạn này được phác họa rõ nét qua sơ đồ tổng quát tại Hình 3-1.



Hình 3-1. Sơ đồ tổng quát quá trình thực hiện

3.2. THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

3.2.1. Thu thập dữ liệu

Dữ liệu lịch sử giá được thu thập từ sàn Binance thông qua thư viện CCXT (CryptoCurrency eXchange Trading Library), là một thư viện mã nguồn mở hỗ trợ truy xuất dữ liệu từ nhiều sàn giao dịch tiền mã hóa qua giao diện thống nhất. Dữ liệu được lấy với khung thời gian 1 giờ, mỗi bản ghi bao gồm các trường như Bảng 3-1. Dữ liệu thô được thu thập từ đầu năm 2019 đến cuối tháng 3/2026 cho cặp giao dịch có vốn hóa và thanh khoản hàng đầu thị trường là BTC/USDT. Tổng cộng, tập dữ liệu thu được khoảng 63445 bản ghi.

Bảng 3-1. Thông tin các trường dữ liệu

STT	Trường	Mô tả
1	Datetime	Thời điểm mở nến
2	Open	Giá mở cửa nến

3	High	Giá cao nhất trong nến			
4	Low	Giá thấp nhất trong nến			
5	Close	Giá đóng cửa nến			
6	Volume	Khối lượng giao dịch			

	open	high	low	close	volume
datetime					
2019-01-01 00:00:00	3701.23	3713.00	3689.88	3700.31	686.367420
2019-01-01 01:00:00	3700.20	3702.73	3684.22	3689.69	613.539115
2019-01-01 02:00:00	3689.67	3695.95	3675.04	3690.00	895.302181
2019-01-01 03:00:00	3690.00	3699.77	3685.78	3693.13	796.714818
2019-01-01 04:00:00	3692.32	3720.00	3685.94	3692.71	1317.452909

Hình 3-2. Một mẫu dữ liệu OHLCV

Cấu trúc của các điểm dữ liệu thô ban đầu, bao gồm chuỗi thời gian và các giá trị OHLCV tương ứng, được minh họa chi tiết tại Hình 3-2. Do nghiên cứu trực tiếp sử dụng nhãn thời gian thực tế (datetime) làm cơ sở để tính toán và trích xuất các đặc trưng, các định nghĩa cơ sở tại mục 2.5.3 cần được mở rộng.

Cụ thể, vector $\mathbf{x}_t$ ở công thức (2-1) được mở rộng thành vector $\tilde{\mathbf{x}}_t$ như sau:

$$\tilde{\mathbf{x}}_t = [\tau_t, x_t^{(o)}, x_t^{(h)}, x_t^{(l)}, x_t^{(c)}, x_t^{(v)}]^T \in \mathbb{R}^6 \quad (3-1)$$

Trong đó τ_t là nhãn thời gian thực tế tại bước quan sát t .

Ma trận giá OHLCV sẽ được mở rộng từ công thức (2-2) và sẽ được thể hiện ở ma trận $\tilde{\mathbf{X}}_{t:T}$ có công thức như sau:

$$\tilde{\mathbf{X}}_{t:T} = \begin{bmatrix} \tilde{\mathbf{x}}_t^T \\ \tilde{\mathbf{x}}_{t+1}^T \\ \vdots \\ \tilde{\mathbf{x}}_T^T \end{bmatrix} \in \mathbb{R}^{N \times 6} \quad (3-2)$$

Để thuận tiện cho việc trình bày và tính toán trong các phần sau, toàn bộ tập dữ liệu thực nghiệm thu thập được quy ước ký hiệu là ma trận $\mathcal{D} = \tilde{\mathbf{X}}_{1:63445}$.

3.2.2. Kiểm định và làm sạch dữ liệu

Trước khi tiến hành bất kỳ phép biến đổi nào, bộ dữ liệu thô được đưa qua quy trình rà soát sơ bộ trên toàn bộ không gian mẫu để đánh giá chất lượng cơ sở. Các thuật toán kiểm tra được áp dụng nhằm xác định sự tồn tại của các

bản ghi bị trùng lặp và các giá trị khuyết thiếu (Null/NaN) tại tất cả các trường thuộc tính. Kết quả kiểm định cho thấy ma trận dữ liệu đạt chuẩn về mặt cấu trúc ban đầu, không chứa các dữ liệu rác hay lỗi thu thập nghiêm trọng, qua đó đảm bảo tính đầy đủ của các biến số tại những thời điểm được hệ thống ghi nhận.

3.2.3. Khám phá dữ liệu và xử lý chuỗi thời gian

Sau bước làm sạch, quá trình phân tích khám phá dữ liệu được thực hiện nhằm hiểu rõ các đặc tính cấu trúc của tập dữ liệu. Kết quả khảo sát cho thấy chuỗi dữ liệu không hoàn toàn liên tục mà xuất hiện một số khoảng gián đoạn tại các thời điểm nhất định. Trong điều kiện lý tưởng, các mốc thời gian liên tiếp cách nhau đúng một giờ.

Tuy nhiên, trong thực tế thu thập, một số mốc thời gian bị khuyết, làm cho chuỗi quan sát trở thành chuỗi lấy mẫu không đều. Tức là với các mẫu dữ liệu liên tiếp từ $\mathcal{D}$, tồn tại các bước quan sát t và $t + 1$ sao cho $\tau_{t+1} - \tau_t > 1$ giờ.

Nguyên nhân của hiện tượng này xuất phát từ đặc thù của nguồn cung cấp dữ liệu (các sản giao dịch), bao gồm các đợt bảo trì hệ thống định kỳ hoặc sự cố mất kết nối mạng tạm thời làm gián đoạn quá trình ghi nhận. Đặc điểm này chỉ ra rằng dữ liệu cần được biểu diễn theo cả giá trị quan sát lẫn thời gian quan sát thực tế, thay vì chỉ dựa trên chỉ số thứ tự thuần túy.

Để bảo toàn tính nguyên bản và độ chân thực của dữ liệu thực nghiệm, quy trình quyết định không sử dụng các kỹ thuật nội suy hay điền bù giá trị. Việc ép buộc trục thời gian trở nên liên tục thông qua nội suy có nguy cơ sinh ra các giá trị giả tạo, làm nhiễu tín hiệu gốc và dẫn đến những sai lệch nghiêm trọng trong việc đánh giá động lực học thực tế của hệ thống. Thay vào đó, sự gián đoạn này được nhìn nhận là một thuộc tính mang giá trị thông tin, phản ánh đúng trạng thái của môi trường tại thời điểm thu thập và sẽ được lượng hóa ở bước tiếp theo.

3.2.4. Xây dựng đặc trưng

3.2.4.1. Đặc trưng gián đoạn thời gian

Để giải quyết bài toán dữ liệu lấy mẫu không đều đã phân tích ở phần trước, nghiên cứu tiến hành trích xuất nhóm đặc trưng đầu tiên nhằm lượng hóa độ trễ giữa các quan sát. Đặc trưng này cung cấp tín hiệu cho mô hình về quy mô của các khoảng trống dữ liệu bị khuyết. Cụ thể, dựa trên nhãn thời gian thực tế τ_t , khoảng cách thời gian giữa hai bước dữ liệu liên tiếp được xác định theo công thức:

$$\Delta\tau_t = \tau_t - \tau_{t-1} \quad (3-3)$$

Trong đó, $\Delta\tau_t$ được tính bằng đơn vị giờ. Trong điều kiện hệ thống vận hành lý tưởng, $\Delta\tau_t$ luôn nhận giá trị hằng số bằng 1. Ngược lại, khi $\Delta\tau_t > 1$, giá trị này phản ánh mức độ kéo dài của các khoảng thời gian bị mất.

Nhằm giảm thiểu tác động của các khoảng gián đoạn quá lớn, giá trị này được chuẩn hóa phi tuyến thông qua hàm logarit tự nhiên. Đặc trưng đầu tiên $f_t^{(1)}$ được định nghĩa như sau:

$$f_t^{(1)} = \ln(\Delta\tau_t) \quad (3-4)$$

3.2.4.2. Đặc trưng chu kỳ thời gian

Bên cạnh yếu tố gián đoạn, thị trường tài chính luôn tồn tại các đặc tính biến động theo khung giờ. Nhằm giúp mô hình học được các quy luật lặp lại theo chu kỳ 24 giờ của thị trường, một cặp đặc trưng thời gian được trích xuất dựa trên phép biến đổi lượng giác, có công thức như sau:

$$f_t^{(2)} = \sin(2\pi \frac{h_t}{24}) \quad (3-5)$$

$$f_t^{(3)} = \cos(2\pi \frac{h_t}{24}) \quad (3-6)$$

Trong đó $h_t \in [0, 23]$ là giờ trong ngày được trích xuất trực tiếp từ nhãn thời gian τ_t .

Việc sử dụng đồng thời cả hai hàm sin và cos giúp ánh xạ một trục thời gian tuyến tính thành các tọa độ hình học trên một vòng tròn đơn vị, nó cho mô hình biết được các thay đổi theo chu kỳ giờ.

3.2.4.3. Đặc trưng về thị trường

Để mô hình nắm bắt được hình thái của thân nến so với toàn bộ biên độ dao động trong phiên, tỷ lệ thân nến được trích xuất. Biến số này giúp nhận diện áp lực mua/bán áp đảo tại bước thời gian t :

$$f_t^{(4)} = \frac{x_t^{(c)} - x_t^{(o)}}{x_t^{(h)} - x_t^{(l)}} \quad (3-7)$$

Nghiên cứu sử dụng tỷ suất sinh lời logarit để đo lường động lượng với nhiều bước thời gian khác nhau nhằm cung cấp góc nhìn đa chiều từ vi mô đến vĩ mô trong ngày, tỷ suất sinh lời được tính toán trên nhiều khung thời gian trễ với công thức tổng quát như sau:

$$Ret_t^{(h)} = \ln \left(\frac{x_t^{(c)}}{x_{t-h}^{(c)}} \right) \quad (3-8)$$

Với h là khoảng thời gian trễ.

Nghiên cứu sẽ tính toán trên nhiều khung thời gian trễ $h \in \{1, 4, 24\}$. Các đặc trưng tỷ suất sinh lời sẽ được tính toán như sau:

$$f_t^{(5)} = Ret_t^{(1)} \quad (3-9)$$

$$f_t^{(6)} = Ret_t^{(4)} \quad (3-10)$$

$$f_t^{(7)} = Ret_t^{(24)} \quad (3-11)$$

Các đặc trưng này cho tác nhân biết được thông tin của các biến động giá diễn ra trong ngày.

Biến động thị trường là một thông số trọng yếu giúp mô hình đánh giá mức độ rủi ro hiện tại của môi trường, từ đó đưa ra các quyết định điều chỉnh vị thế giao dịch phù hợp. Nghiên cứu sử dụng độ lệch chuẩn của tỷ suất sinh lời 1 giờ để định lượng mức độ biến động này. Với công thức tổng quát như sau:

$$\bar{R}_t^{(w)} = \frac{1}{w} \sum_{i=0}^{w-1} Ret_{t-i}^{(1)} \quad (3-12)$$

$$\sigma_t^{(w)} = \sqrt{\frac{1}{w-1} \sum_{i=0}^{w-1} (Ret_{t-i}^{(1)} - \bar{R}_t^{(w)})^2} \quad (3-13)$$

Nghiên cứu sẽ tính biến động trong khung cửa sổ kích cỡ 4, được định nghĩa như sau:

$$f_t^{(8)} = \sigma_t^{(4)} \quad (3-14)$$

Nghiên cứu tính tỷ lệ biến động gần đây với một khung biến động có kích cỡ 24 để biết được độ biến động gần nhất như thế nào so với khung biến động xa hơn, tỷ lệ này sẽ được tính như sau:

$$f_t^{(9)} = \frac{\sigma_t^{(4)}}{\sigma_t^{(24)}} \quad (3-15)$$

Các chỉ báo kỹ thuật đã được định nghĩa tại mục 2.5.4 sẽ được đưa vào làm các đặc trưng của mô hình.

Dựa trên định nghĩa VWAP tại công thức (2-12), thay vì đưa trực tiếp giá trị tuyệt đối của VWAP, nghiên cứu trích xuất khoảng cách tương đối giữa giá đóng cửa và VWAP, được thể hiện bởi:

$$f_t^{(10)} = \frac{x_t^{(c)} - VWAP_t^{(24)}}{VWAP_t^{(24)}} \quad (3-16)$$

Tiếp theo, các chỉ báo động lượng và xu hướng được thể hiện bằng các đặc trưng $f_t^{(11)}$ đến $f_t^{(15)}$, các đặc trưng này có công thức như sau:

$$f_t^{(11)} = \frac{RSI_t^{(14)}}{100} \quad (3-17)$$

$$f_t^{(12)} = \%B_t^{(20)} \quad (3-18)$$

$$f_t^{(13)} = \frac{ADX_t^{(14)}}{100} \quad (3-19)$$

$$f_t^{(14)} = \frac{MFI_t^{(14)}}{100} \quad (3-20)$$

$$f_t^{(15)} = \frac{W\%R_t^{(14)} + 100}{100} \quad (3-21)$$

3.2.4.4. Tổng hợp đặc trưng

Sau khi hoàn tất quá trình trích xuất, toàn bộ các thông tin của thị trường tại bước t được thể hiện ở một vector. Cấu trúc này được định nghĩa là vector trạng thái thị trường, được định nghĩa như sau:

$$\mathbf{z}_t = [f_t^{(1)}, f_t^{(2)}, f_t^{(3)}, \dots, f_t^{(15)}]^\top \in \mathbb{R}^{15} \quad (3-22)$$

Tuy nhiên, trong các bài toán giao dịch tài chính, việc chỉ quan sát một điểm dữ liệu tĩnh $\mathbf{z}_t$ là không đủ để mạng nơ-ron nắm bắt được các chuỗi mẫu hình và xu hướng. Do đó, dữ liệu đầu vào thực tế cho mô hình tại mỗi bước ra quyết định sẽ là một chuỗi các vector trạng thái trong quá khứ, được ghép lại thành ma trận thị trường $\mathbf{M}_t^{(w)}$:

$$\mathbf{M}_t^{(w)} = \begin{bmatrix} \mathbf{z}_{t-w+1}^\top \\ \mathbf{z}_{t-w+2}^\top \\ \vdots \\ \mathbf{z}_t^\top \end{bmatrix} \in \mathbb{R}^{w \times 15} \quad (3-23)$$

Trong đó, w là kích thước cửa sổ dữ liệu, đóng vai trò như một siêu tham số quyết định độ dài chuỗi dữ liệu ở quá khứ mô hình có thể xem.

Trong phạm vi nghiên cứu này, tham số w được thiết lập bằng 24. Điều này đồng nghĩa với việc tại mỗi bước thời gian t , mô hình tiếp nhận đầu vào là ma trận $\mathbf{M}_t^{(24)}$, cho phép mô hình trực tiếp quan sát và học hỏi từ toàn bộ bức tranh biến động của thị trường trong 24 giờ gần nhất để đưa ra quyết định giao dịch tối ưu.

datetime	log_time_gap	hour_sin	hour_cos	body_ratio	log_ret_1	log_ret_4	log_ret_24	volatility_4	volatility_24_ratio	dist_vwap_24	rsi_14	bb_percent_b	adx_14	mfi_14	williams_r_14
2020-01-01 00:00:00	0.0	0.000000	1.000000	-0.876383	-0.002534	0.000085	-0.010255	0.002062	0.868509	-0.006511	0.364014	0.203354	0.221157	0.451141	0.182925
2020-01-01 01:00:00	0.0	0.258819	0.965926	0.733100	0.005454	0.004177	-0.006785	0.003478	1.327332	-0.000813	0.484911	0.538013	0.209931	0.455621	0.407223
2020-01-01 02:00:00	0.0	0.500000	0.866025	0.816796	0.003677	0.005867	-0.000571	0.003724	1.382640	0.002928	0.547625	0.767512	0.204227	0.503067	0.559118
2020-01-01 03:00:00	0.0	0.707107	0.707107	-0.706000	-0.002466	0.004130	-0.001574	0.004143	1.520771	0.000470	0.503330	0.630397	0.198972	0.446168	0.457169
2020-01-01 04:00:00	0.0	0.866025	0.500000	-0.516366	-0.001072	0.005593	-0.003196	0.003772	1.382208	-0.000501	0.485000	0.567066	0.191942	0.296587	0.622877

Hình 3-3. Đặc trưng tiền xử lý

Hình 3-3 thể hiện dữ liệu đã tiền xử lý.

3.2.5. Phân chia và chuẩn hóa dữ liệu

Trong quá trình tính toán các đặc trưng và chỉ báo phân tích kỹ thuật, một số quan sát ở giai đoạn đầu của chuỗi thời gian sẽ phát sinh giá trị khuyết do không có đủ dữ liệu lịch sử để đáp ứng độ dài của cửa sổ tính toán. Ban đầu, nghiên cứu chỉ dự định sử dụng dữ liệu từ năm 2020 trở đi; tuy nhiên, để khắc phục triệt để tình trạng thiếu hụt quan sát ở giai đoạn đầu mà không làm mất đi các dữ liệu quan trọng trong giai đoạn phân tích, bộ dữ liệu thô đã được mở rộng thu thập từ năm 2019. Phần dữ liệu bổ sung này chủ yếu được sử dụng làm vùng đệm nhằm phục vụ việc tính toán các đặc trưng dựa trên dữ liệu quá khứ, qua đó bảo đảm rằng các quan sát từ năm 2020 trở đi vẫn được giữ nguyên trong tập dữ liệu chính thức.

Sau khi loại bỏ phần dữ liệu đệm, tập dữ liệu chính thức được sử dụng để huấn luyện và đánh giá mô hình bao gồm các quan sát từ ngày 01/01/2020 đến hết tháng 03/2026. Việc giới hạn phạm vi nghiên cứu trong giai đoạn này là một lựa chọn có chủ đích, nhằm ưu tiên các quan sát phản ánh bối cảnh thị trường hiện đại. Cách tiếp cận này giúp mô hình học được những đặc trưng gần với điều kiện giao dịch hiện tại, đồng thời hạn chế ảnh hưởng của các mẫu hình hoặc quy luật thị trường thuộc những giai đoạn trước đó. Trên cơ sở đó, tập dữ liệu chính thức được phân chia theo trình tự thời gian thành ba tập con riêng biệt như trình bày trong Bảng 3-2.

Bảng 3-2. Phân chia dữ liệu

Tên	Phạm vi	Ý nghĩa
Tập huấn luyện	01/01/2020 – 29/02/2024	Dữ liệu dùng để huấn luyện
Tập đánh giá	01/03/2024 – 31/08/2024	Dữ liệu dùng để đánh giá trong quá trình huấn luyện để chọn ra mô hình tốt nhất
Tập kiểm thử	01/09/2024 – 31/03/2026	Dữ liệu kiểm thử mô hình sau khi hoàn thành huấn luyện

Dữ liệu sau đó sẽ được chuẩn hóa bằng phương pháp Z-score Standardization.

$$x' = \frac{x - \mu}{\sigma}$$

Trong đó μ là trung bình và σ là độ lệch chuẩn. Để tránh rò rỉ thông tin, các tham số μ và σ được tính riêng trên tập huấn luyện, sau đó áp dụng lên tập đánh giá và tập kiểm thử.

3.3. THIẾT KẾ MÔI TRƯỜNG GIAO DỊCH

Để giải bài toán phân bổ tỷ trọng crypto theo thời gian, nghiên cứu xây dựng một môi trường giao dịch theo hướng học tăng cường. Môi trường được thiết kế sao cho mỗi quyết định của tác nhân gắn với một bước thời gian cụ thể trong chuỗi dữ liệu lịch sử, đồng thời phản ánh tác động của quyết định đó lên giá trị danh mục sau khi đã xét đến chi phí giao dịch. Về mặt lý thuyết, bài toán được mô hình hóa dưới dạng một MDP. Về mặt thực thi, môi trường đóng vai trò hiện thực hóa các thành phần của MDP, bao gồm trạng thái, hành động, chuyển trạng thái và phần thưởng.

Vì thuật toán được sử dụng là PPO theo hướng model-free, tác nhân không học một mô hình động lực học tường minh của thị trường. Thay vào đó, tác nhân học trực tiếp từ các mẫu tương tác dạng (s_t, a_t, r_t, s_{t+1}) do môi trường sinh ra trong quá trình huấn luyện. Do đó, trong nghiên cứu này, hàm chuyển trạng thái không được mô hình hóa tường minh mà được xác định thông qua quy tắc cập nhật của môi trường dựa trên dữ liệu giá lịch sử và hành động do tác nhân lựa chọn.

3.3.1. Mô hình hóa dưới dạng MDP

Bài toán giao dịch được biểu diễn bởi bộ bốn thành phần $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R} \rangle$, trong đó $\mathcal{S}$ là không gian trạng thái, $\mathcal{A}$ là không gian hành động, $\mathcal{P}$ là hàm chuyển trạng thái và $\mathcal{R}$ là hàm phần thưởng. Mục tiêu của tác nhân là học được một chính sách $\pi(a_t | s_t)$ sao cho tổng phần thưởng kỳ vọng trong toàn bộ quá trình giao dịch là lớn nhất.

Tại mỗi thời điểm t , môi trường cung cấp cho tác nhân một trạng thái s_t phản ánh đồng thời bối cảnh thị trường và tình trạng danh mục hiện tại. Dựa trên trạng thái này, tác nhân lựa chọn một hành động a_t để xác định tỷ trọng crypto mục tiêu trong danh mục. Sau khi hành động được thực thi, môi trường cập nhật danh mục theo biến động giá, tính toán phần thưởng, và sinh ra trạng thái mới s_{t+1} .

3.3.2. Không gian trạng thái

Không gian trạng thái được xây dựng từ các thông tin cần thiết để tác nhân có thể ra quyết định tại mỗi bước thời gian. Cụ thể, trạng thái tại thời điểm t bao gồm thông tin thị trường trong một cửa sổ quan sát gần nhất, cùng với các đặc trưng phản ánh tình trạng danh mục hiện tại. Trong khuôn khổ mô hình này, trạng thái được biểu diễn bởi:

$$\begin{aligned} s_t &= (\mathbf{M}_t^{(24)}, \mathbf{p}_t) \in \mathcal{S}, \\ \mathcal{S} &= \mathbb{R}^{24 \times 15} \times \mathbb{R}^{1 \times 4} \end{aligned} \tag{3-24}$$

Với $\mathbf{M}_t^{(24)}$ là ma trận giá thị trường với cửa sổ 24 đã được định nghĩa ở công thức (3-23) và $\mathbf{p}_t$ là vector thông tin danh mục tại thời điểm t . Vector này được xác định bởi:

$$\mathbf{p}_t = [p_t^{(1)}, p_t^{(2)}, p_t^{(3)}, p_t^{(4)}]^\top \in \mathbb{R}^{1 \times 4} \quad (3-25)$$

Trong đó, $p_t^{(1)}$ biểu diễn tỷ trọng tiền pháp định trong tổng giá trị danh mục, $p_t^{(2)}$ biểu diễn tỷ trọng giá trị tài sản crypto trong danh mục, $p_t^{(3)}$ biểu diễn log-return tích lũy của danh mục so với giá trị ban đầu, và $p_t^{(4)}$ biểu diễn log-return của danh mục tại bước thời gian hiện tại. Cụ thể, các thành phần này được xác định như sau:

$$p_t^{(1)} = \frac{F_t}{E_t} \quad (3-26)$$

$$p_t^{(2)} = \frac{Q_t \cdot x_t^{(c)}}{E_t} \quad (3-27)$$

$$p_t^{(3)} = \ln\left(\frac{E_t}{E_0}\right) \quad (3-28)$$

$$p_t^{(4)} = \ln\left(\frac{E_t}{E_{t-1}}\right) \quad (3-29)$$

Vector $\mathbf{p}_t$ phản ánh trạng thái nội tại của danh mục tại thời điểm t , bao gồm tỷ trọng tiền pháp định, tỷ trọng tài sản crypto, mức sinh lời tích lũy của danh mục và mức sinh lời theo từng bước thời gian. Việc đưa các đặc trưng này vào không gian trạng thái cho phép tác nhân đồng thời quan sát cấu trúc phân bổ tài sản và hiệu quả đầu tư hiện tại, từ đó hình thành quyết định giao dịch phù hợp hơn.

3.3.3. Không gian hành động

Tại mỗi bước tác nhân đưa ra một hành động a_t , được định nghĩa như sau:

$$a_t \in \mathcal{A}, \mathcal{A} \subseteq [0, 1] \quad (3-30)$$

Không gian hành động của tác nhân là một không gian liên tục trên đoạn $[0, 1]$. Tại mỗi bước thời gian, tác nhân sinh ra một giá trị $a_t \in [0, 1]$, trong đó a_t biểu diễn tỷ trọng mục tiêu của crypto trong tổng danh mục tại thời điểm t . Khi $a_t = 0$, danh mục không nắm giữ crypto; khi $a_t = 1$, toàn bộ danh mục được phân bổ vào crypto. Các giá trị nằm giữa hai đầu mút này tương ứng với các mức phân bổ trung gian.

Thiết kế hành động liên tục như vậy giúp tác nhân không chỉ đưa ra các quyết định rời rạc như mua, bán hoặc giữ, mà còn học cách điều chỉnh linh hoạt tỷ trọng vốn trong danh mục tại mỗi thời điểm. Cách tiếp cận này phù hợp với

bài toán phân bổ tài sản, trong đó mục tiêu là tối ưu hóa hiệu quả đầu tư trong dài hạn dưới các ràng buộc của thị trường và chi phí giao dịch.

3.3.4. Cơ chế chuyển trạng thái và cập nhật danh mục

Trong mô hình giao dịch sử dụng PPO, quá trình chuyển trạng thái không được biểu diễn bằng một phương trình động lực học tường minh của thị trường, mà được hiện thực hóa trực tiếp trong môi trường mô phỏng. Tại mỗi bước thời gian t , tác nhân quan sát trạng thái thị trường hiện tại và đưa ra hành động a_t , trong đó $a_t \in [0,1]$ biểu diễn tỷ trọng mục tiêu phân bổ vào tài sản crypto. Trên cơ sở hành động này, môi trường tiến hành tái cân bằng danh mục, đồng thời mô phỏng các yếu tố thị trường thực tế như độ trễ khớp lệnh, trượt giá và phí giao dịch. Cơ chế cập nhật được triển khai theo trình tự từ thời điểm mở cửa đến thời điểm nền đóng cửa, qua đó xác định trạng thái danh mục tại bước kế tiếp.

3.3.4.1. Tính toán tỷ trọng trôi dạt

Tại thời điểm bắt đầu bước thời gian t , môi trường cung cấp quan sát thị trường mới nhất cho tác nhân, trong đó giá mở cửa của tài sản crypto tại thời điểm t được ký hiệu là $x_t^{(o)}$. Trước khi tác nhân thực hiện bất kỳ quyết định nào, giá trị danh mục đã thay đổi do biến động giá từ kỳ trước sang kỳ hiện tại. Cụ thể, nếu F_{t-1} là số dư tiền pháp định và Q_{t-1} là khối lượng crypto nắm giữ tại cuối bước $t-1$, thì tổng giá trị tạm thời của danh mục tại thời điểm mở cửa được xác định bởi:

$$E_t^{(temp)} = F_{t-1} + Q_{t-1}x_t^{(o)} \quad (3-31)$$

Từ đó, tỷ trọng crypto thực tế sau khi giá biến động, nhưng trước khi tái cân bằng, được tính theo:

$$w'_t = \frac{Q_{t-1}x_t^{(o)}}{E_t^{(temp)}} \quad (3-32)$$

Đại lượng w'_t phản ánh tỷ trọng trôi dạt của danh mục tại thời điểm quan sát, và đóng vai trò là trạng thái đầu vào trực tiếp cho quyết định tái cân bằng của tác nhân.

3.3.4.2. Ra quyết định chuyển đổi tỷ trọng danh mục

Sau khi quan sát trạng thái hiện tại, tác nhân lựa chọn hành động a_t , tương ứng với tỷ trọng mục tiêu mà danh mục cần hướng tới sau khi tái cân bằng. Mức chênh lệch giữa tỷ trọng mục tiêu và tỷ trọng trôi dạt được xác định bởi:

$$\delta_t = |a_t - w'_t| \quad (3-33)$$

Để hạn chế các giao dịch có quy mô quá nhỏ và giảm thiểu hiện tượng nhiễu do tái cân bằng liên tục, môi trường sử dụng một ngưỡng giao dịch τ . Nếu $\delta_t < \tau$, danh mục được giữ nguyên và không phát sinh lệnh giao dịch. Ngược lại, khi $\delta_t \geq \tau$, hệ thống kích hoạt quá trình khớp lệnh nhằm điều chỉnh danh mục từ trạng thái hiện tại về mức phân bổ mục tiêu a_t .

Giá trị danh nghĩa cần được điều chỉnh trong bước tái cân bằng được xác định bởi:

$$V_{trade} = \delta_t E_t^{(temp)} \quad (3-34)$$

Đại lượng này biểu thị quy mô vốn cần chuyển đổi giữa tiền pháp định và crypto để đạt tới tỷ trọng mong muốn.

3.3.4.3. Thực thi lệnh

Khi lệnh giao dịch được kích hoạt, môi trường mô phỏng quá trình khớp lệnh theo hai khả năng: mua hoặc bán crypto, tùy thuộc vào dấu của $a_t - w'_t$. Trong quá trình này, các cơ chế thị trường như trượt giá và phí giao dịch được áp dụng nhằm phản ánh điều kiện giao dịch thực tế.

Trường hợp $a_t - w'_t > 0$ cho thấy tác nhân cần gia tăng tỷ trọng crypto trong danh mục. Khi đó, giá thực thi mua được điều chỉnh theo trượt giá bất lợi cho bên mua:

$$P_{buy} = x_t^{(o)}(1 + s) \quad (3-35)$$

Trong đó s là hệ số trượt giá. Khối lượng crypto mua lý thuyết trước khi trừ phí là:

$$\Delta Q_t^{(buy)} = \frac{V_{trade}}{P_{buy}} \quad (3-36)$$

Sau khi tính đến phí giao dịch với tỷ lệ c , khối lượng crypto thực nhận được là:

$$Q_t = Q_{t-1} + \Delta Q_t^{(buy)}(1 - c) \quad (3-37)$$

Đồng thời, số dư tiền pháp định sau giao dịch được cập nhật thành:

$$F_t = F_{t-1} - V_{trade} \quad (3-38)$$

Ngược lại, khi $a_t - w'_t < 0$, tác nhân cần giảm tỷ trọng crypto. Trong trường hợp này, giá thực thi bán chịu tác động của trượt giá theo chiều bất lợi cho bên bán:

$$P_{sell} = x_t^{(o)}(1 - s) \quad (3-39)$$

Khối lượng crypto cần bán để giải phóng một giá trị danh nghĩa bằng V_{trade} được xác định bởi:

$$\Delta Q_t^{(sell)} = \frac{V_{trade}}{x_t^{(o)}} \quad (3-40)$$

Sau khi trừ phí giao dịch, số tiền pháp định thu về được xác định bởi:

$$F_t = F_{t-1} + V_{trade}(1 - c) \quad (3-41)$$

Trong khi khối lượng crypto còn lại trong danh mục được cập nhật theo:

$$Q_t = Q_{t-1} - \Delta Q_t^{(sell)} \quad (3-42)$$

Cách mô phỏng này cho phép phản ánh đồng thời chi phí giao dịch và tác động của trượt giá, nhờ đó giúp quá trình huấn luyện gần hơn với điều kiện thị trường thực tế. Hệ số trượt giá s , trong nghiên cứu này là 0.01%.

3.3.4.4. Cập nhật danh mục cuối kỳ

Khi bước thời gian t kết thúc và nền giá đóng cửa được hình thành, mức giá đóng cửa của tài sản crypto được ký hiệu là $x_t^{(c)}$. Sau khi quá trình khớp lệnh tại giá mở cửa hoàn tất và các chi phí giao dịch đã được tính đến, số dư tiền pháp định F_t và khối lượng crypto Q_t được cố định cho đến cuối bước.

Tại thời điểm này, tổng giá trị danh mục cuối kỳ được xác định bởi:

$$E_t = F_t + Q_t x_t^{(c)} \quad (3-43)$$

Việc sử dụng giá đóng cửa để định giá danh mục giúp hàm phần thưởng phản ánh kết quả đầu tư của cả chu kỳ giao dịch, thay vì chỉ phụ thuộc vào mức giá thực thi lệnh tại thời điểm tái cân bằng. Cách thiết kế này tạo ra một cơ chế mô phỏng nhất quán cho từng bước thời gian, đồng thời cung cấp nền tảng để tác nhân PPO tối ưu hóa chính sách phân bổ tài sản trong các bước tiếp theo.

3.3.5. Hàm phần thưởng

Thiết kế hàm phần thưởng là một trong những yếu tố quyết định hành vi học được của tác nhân, vì nó xác định trực tiếp mục tiêu tối ưu hóa trong quá trình huấn luyện. Trong nghiên cứu này, phần thưởng tại mỗi bước thời gian được xây dựng trên cơ sở so sánh suất sinh lời của danh mục với suất sinh lời của thị trường, nhằm tạo ra một mốc tham chiếu để đánh giá hiệu quả giao dịch. Cách thiết kế này khuyến khích tác nhân không chỉ tối đa hóa lợi nhuận tuyệt đối của danh mục, mà còn cải thiện hiệu quả tương đối so với diễn biến chung của thị trường.


Cụ thể, phần thưởng tại bước thời gian t được xác định bởi:

$$r_t = \left(\frac{E_t - E_{t-1}}{E_{t-1}} \right) - \alpha \left(\frac{x_t^{(c)} - x_{t-1}^{(c)}}{x_{t-1}^{(c)}} \right) \quad (3-44)$$

Trong đó, thành phần thứ nhất biểu diễn suất sinh lời đơn giản của danh mục trong bước thời gian t , còn thành phần thứ hai biểu diễn suất sinh lời của thị trường. Hệ số α được sử dụng để điều chỉnh mức độ ảnh hưởng của thành phần thị trường trong hàm phần thưởng, qua đó cân bằng giữa mục tiêu tối đa hóa lợi nhuận danh mục và mục tiêu vượt trội so với diễn biến thị trường. Nghiên cứu sẽ sử dụng mức α là 0.9.

3.4. THIẾT KẾ TÁC NHÂN

3.4.1. Tổng quan kiến trúc



Hình 3-4. Kiến trúc mô hình tổng quan

Kiến trúc tổng quan của mô hình được thể hiện ở Hình 3-4 bao gồm 2 thành phần chính là Feature Extractor và khối PPO. Cả 2 khối này có tác dụng khác nhau, khối Feature Extractor thực hiện việc trích xuất các đặc trưng từ dữ liệu bằng các mô hình khác nhau bao gồm GRU và LSTM trước khi đi vào khối PPO. Khối PPO 2 mạng Actor và Critic là 2 mạng MLP dùng để đưa ra quyết định và đưa ra giá trị của trạng thái.

3.4.2. Khối trích xuất đặc trưng (Feature Extractor)

Tại mỗi bước t , khối này sẽ nhận đầu vào là $s_t = (\mathbf{M}_t^{(24)}, \mathbf{p}_t)$ như đã được định nghĩa ở công thức (3-24). Nhiệm vụ của khối này là trích xuất và tổng hợp các đặc trưng có ý nghĩa từ dữ liệu đầu vào, qua đó tạo ra biểu diễn đặc trưng phục vụ cho bước ra quyết định tiếp theo của tác nhân.

Trong nghiên cứu này, khối trích xuất đặc trưng chuỗi thời gian được khảo sát dưới hai kiến trúc khác nhau, bao gồm GRU và LSTM, nhằm đánh giá và so sánh hiệu năng của từng mô hình trong việc khai thác thông tin từ dữ liệu thị trường. Dữ liệu đầu vào $\mathbf{M}_t^{(24)}$ trước hết được đưa qua một trong các mô hình trên để học biểu diễn động theo thời gian. Sau khi đầu ra của GRU/LSTM thu được chuỗi vector ẩn $[h_1, h_2, \dots, h_T]$, với $h_i \in \mathbb{R}^d$ là biểu diễn tại bước thời gian thứ i , lớp Attention Pooling được sử dụng để xác định mức độ quan trọng của từng trạng thái ẩn trong chuỗi. Thay vì chỉ sử dụng trực tiếp vector cuối cùng h_T cho lớp kế tiếp, nghiên cứu này áp dụng cơ chế attention nhằm khai

thác và tổng hợp thông tin từ toàn bộ các trạng thái ẩn, dựa trên ý tưởng được đề xuất bởi Yang và c.s (2016). Cụ thể, với mỗi vector h_i , mô hình tính điểm chú ý theo công thức:

$$e_i = w_2^\top \phi(W_1 h_i + b_1) + b_2, \quad (3-45)$$


Trong đó $W_1 \in \mathbb{R}^{\frac{d}{2} \times d}$, $b_1 \in \mathbb{R}^{\frac{d}{2}}$, $w_2 \in \mathbb{R}^{\frac{d}{2}}$ và $b_2 \in \mathbb{R}$ là các tham số học được; $\phi(\cdot)$ là hàm kích hoạt GELU. Sau đó được biến đổi bằng hàm softmax:

$$\alpha_i = \frac{\exp(e_i)}{\sum_{j=1}^T \exp(e_j)}, \quad (3-46)$$

Vector đầu ra được tính bằng phép tổng có trọng số:

$$c_t = \sum_{i=1}^T \alpha_i h_i. \quad (3-47)$$


Trong đó, c_t là biểu diễn đã được tổng hợp thông tin theo thời gian, trong đó các thời điểm có đóng góp quan trọng hơn sẽ nhận trọng số lớn hơn. Tiếp theo, đặc trưng đã được tổng hợp từ chuỗi thời gian được ghép nối với vector $\mathbf{p}_t$ thông qua phép concat, nhằm kết hợp đồng thời thông tin thị trường và thông tin nội tại của danh mục. Biểu diễn kết hợp này sau đó được đưa vào một khối MLP để thực hiện quá trình tổng hợp đặc trưng ở mức cao hơn, qua đó tạo ra đầu ra cuối cùng phục vụ cho tác nhân PPO trong việc xác định hành động tối ưu tại bước thời gian hiện tại.



Chú thích ký hiệu:

$\times$: Phép nhân từng phần tử (Element-wise multiplication).
 Σ : Phép tính tổng dọc theo chiều thời gian.

Hình 3-5. GRU Feature Extractor




Chú thích ký hiệu:

$\times$: Phép nhân từng phần tử (Element-wise multiplication).
 Σ : Phép tính tổng dọc theo chiều thời gian.

Hình 3-6. LSTM Feature Extractor

Hình 3-5, Hình 3-6 thể hiện kiến trúc của từng mô hình sử dụng để trích xuất đặc trưng.

3.4.3. Khối PPO



Hình 3-7. Kiến trúc của khối PPO

Sau khi đặc trưng đầu vào được trích xuất từ khối Feature Extractor, biểu diễn này được đưa vào khối PPO. Cụ thể, tại mỗi bước thời gian t , vector đặc trưng thu được từ khối trước được sử dụng làm đầu vào chung cho hai nhánh mạng độc lập là nhánh Actor và nhánh Critic. Cách thiết kế này cho phép mô hình vừa học chính sách giao dịch tối ưu, vừa học một hàm đánh giá trạng thái phục vụ cho việc cập nhật chính sách theo cơ chế của thuật toán PPO.

Nhánh Actor, ký hiệu là $\pi_{\theta}(a_t | s_t)$, có nhiệm vụ ánh xạ trạng thái hiện tại s_t sang phân phối hành động trên không gian hành động liên tục $[0, 1]$. Trong bối cảnh bài toán giao dịch danh mục, hành động a_t được diễn giải là tỷ trọng mục tiêu mà tác nhân mong muốn phân bổ vào tài sản crypto tại bước thời gian tương ứng. Để đảm bảo đầu ra của mô hình phù hợp với miền giá trị mong muốn, các lớp tuyến tính trong nhánh actor được kết hợp với hàm kích hoạt phi tuyến GELU, qua đó tăng năng lực biểu diễn của mạng và giúp mô hình học được quan hệ phi tuyến giữa trạng thái thị trường và quyết định phân bổ vốn.

Song song với đó, nhánh Critic, ký hiệu là $V_{\phi}(s_t)$, có nhiệm vụ ước lượng giá trị kỳ vọng của trạng thái hiện tại. Giá trị này phản ánh mức độ thuận lợi của trạng thái quan sát đối với chiến lược giao dịch đang được theo đuổi, đồng thời đóng vai trò là nền tảng để tính toán advantage trong quá trình cập

nhất chính sách. Việc sử dụng Critic giúp giảm phương sai của ước lượng gradient, từ đó cải thiện tính ổn định và tốc độ hội tụ của quá trình huấn luyện PPO.

Cả hai nhánh Actor và Critic đều được xây dựng theo kiến trúc MLP nhiều lớp, gồm các tầng tuyến tính xen kẽ với hàm kích hoạt GELU. Cấu trúc này giúp mô hình thực hiện quá trình tổng hợp đặc trưng ở mức cao hơn từ biểu diễn đầu ra của Feature Extractor, trước khi chuyển sang dự đoán hành động hoặc giá trị trạng thái. Trong đó, đầu ra của Actor được sử dụng để sinh quyết định giao dịch tại bước hiện tại, còn đầu ra của critic được dùng để phục vụ quá trình tối ưu hóa chính sách theo cơ chế PPO. Nhờ vậy, khối PPO không chỉ đóng vai trò là bộ ra quyết định, mà còn là thành phần trung tâm đảm bảo sự ổn định của toàn bộ quá trình học tăng cường.

Hình 3-7 minh họa luồng xử lý của khối PPO với dữ liệu đã được trích xuất từ khối trước.

3.5. THIẾT LẬP THỰC NGHIỆM

Để đánh giá hiệu quả của mô hình đề xuất, nghiên cứu tiến hành thiết lập các kịch bản thực nghiệm với cấu hình huấn luyện và tham số thời gian khác nhau. Mục tiêu của phần thực nghiệm không chỉ là đo lường hiệu năng giao dịch của tác nhân trong điều kiện mô phỏng, mà còn là kiểm tra mức độ ảnh hưởng của kiến trúc trích xuất đặc trưng và độ dài episode đến khả năng học chính sách của mô hình. Thông qua đó, nghiên cứu có thể xác định cấu hình nào mang lại hiệu quả ổn định và phù hợp hơn đối với bài toán giao dịch crypto theo hướng học tăng cường.

3.5.1. Các siêu tham số

Bảng 3-3. Các siêu tham số của mô hình

Siêu tham số	Ký hiệu	Giá trị	Ý nghĩa
Learning rate	α	9e-5	Tốc độ học
Hệ số chiết khấu	γ	0.99	Mức độ coi trọng phần thưởng tương lai
GAE lambda	λ	0.95	Cân bằng bias-variance trong ước lượng lợi thế
Clip range	ϵ	0.2	Phạm vi cắt ngưỡng trong L^{CLIP}
N steps	T	2048	Số bước tương tác với môi

Batch size	M	512	trường để thu thập dữ liệu trong một chu kỳ
Epochs per update		7	Kích thước mẫu dữ liệu đưa vào mạng để cập nhật trọng số
Target KL divergence		0.02	Số lần cập nhật trên mỗi batch
Entropy coefficient	c_2	0.01	Ngưỡng phân kỳ tối đa kích hoạt
Value loss coefficient	c_1	0.5	dừng sớm để bảo toàn sự ổn định của chính sách
Total timesteps		2600000	Khuyến khích khám phá
			Trọng số loss của Critic
			Tổng bước huấn luyện

Các siêu tham số của mô hình khi huấn luyện được mô tả ở bảng Bảng 3-3.

3.5.2. Mô hình huấn luyện

Trong giai đoạn thực nghiệm, tác nhân được huấn luyện lần lượt với hai cấu hình Feature Extractor khác nhau, tương ứng với hai kiến trúc được minh họa trong Hình 3-5, Hình 3-6. Cụ thể, các mô hình được khảo sát bao gồm GRU và LSTM. Việc xây dựng nhiều biến thể Feature Extractor nhằm mục đích đánh giá vai trò của khối trích xuất đặc trưng trong việc học biểu diễn dữ liệu thị trường, từ đó so sánh ảnh hưởng của từng kiến trúc đến hiệu quả tối ưu chính sách.

Trong bài toán giao dịch tài sản số, dữ liệu đầu vào có tính chất chuỗi thời gian và chứa nhiều biến động phi tuyến. Do đó, việc lựa chọn kiến trúc Feature Extractor phù hợp có ý nghĩa quan trọng đối với khả năng khai thác thông tin quá khứ, nắm bắt xu hướng thị trường và tạo ra biểu diễn đặc trưng có giá trị cho khối PPO phía sau. Bằng cách huấn luyện và so sánh các mô hình trên trong cùng một môi trường và với cùng một quy trình học, nghiên cứu có thể đánh giá khách quan mức độ phù hợp của từng kiến trúc đối với bài toán đang xét.

3.5.3. Độ dài episode

Trong học tăng cường, episode là một chuỗi tương tác hoàn chỉnh giữa tác nhân và môi trường, được tính từ trạng thái khởi tạo cho đến khi kết thúc theo một tiêu chí xác định trước. Độ dài episode là một tham số quan trọng vì nó quyết định phạm vi thời gian mà tác nhân sử dụng để tích lũy phần thưởng và cập nhật chính sách. Khi episode ngắn, tác nhân có xu hướng tối ưu theo biến động ngắn hạn của thị trường; ngược lại, khi episode dài hơn, tác nhân phải học cách cân bằng giữa lợi nhuận trước mắt và hiệu quả dài hạn trong một chuỗi quan sát có độ bao phủ lớn hơn.

Trong nghiên cứu này, độ dài episode được khảo sát tại ba mức: 720, 2160 và 4320 bước thời gian, tương ứng xấp xỉ với 1 tháng, 3 tháng và 6 tháng dữ liệu giao dịch. Việc lựa chọn các mốc này nhằm phản ánh những khoảng thời gian có ý nghĩa trong thực tiễn đầu tư và giao dịch tài chính, đồng thời cho phép kiểm tra mức độ nhạy của mô hình đối với quy mô của số huấn luyện. Thông qua thực nghiệm này, nghiên cứu có thể quan sát liệu tác nhân học tốt hơn khi tối ưu trên các episode ngắn với phản hồi nhanh của thị trường, hay trên các episode dài hơn với khả năng nắm bắt xu hướng và biến động trung hạn rõ rệt hơn.

3.5.4. Hàm kích hoạt

Trong các lớp ẩn của hai mạng Actor và Critic, mô hình sử dụng hàm kích hoạt GeLU, được định nghĩa là $\text{GeLU}(x) = x\Phi(x)$, trong đó $\Phi(x)$ là hàm phân phối tích lũy của phân phối chuẩn $\mathcal{N}(0,1)$. GeLU được lựa chọn thay vì ReLU dựa trên ba đặc tính kỹ thuật.

Thứ nhất, GeLU là hàm khả vi vô hạn và duy trì gradient khác không ngay cả với đầu vào âm có biên độ nhỏ, trong khi ReLU triệt tiêu hoàn toàn gradient cho mọi đầu vào âm. Điều này giảm thiểu hiện tượng neuron chết - một vấn đề đáng lưu ý trong học sâu, nơi phân phối đầu vào thay đổi liên tục khi chính sách được cập nhật, làm tăng nguy cơ các neuron bị đẩy vĩnh viễn sang vùng không hoạt động.

Thứ hai, GeLU cung cấp cơ chế ngưỡng mềm thay vì ngưỡng cứng. Mỗi giá trị đầu vào được nhân với xác suất $\Phi(x)$: đầu vào có cường độ lớn được giữ lại gần như nguyên vẹn, trong khi đầu vào quanh vùng không bị suy giảm một cách liên tục thay vì bị cắt tại một ngưỡng cố định. Cơ chế này tạo ra hàm chuyển đổi trơn hơn, có lợi cho quá trình tối ưu hóa dựa trên gradient.

Thứ ba, GeLU tiệm cận tuyến tính khi $x \rightarrow +\infty$ nên không gặp hiện tượng gradient tiêu biến ở vùng dương lớn - tránh được hạn chế của tanh và

sigmoid, vốn bão hòa ở cả hai đầu phổ giá trị - đồng thời vẫn duy trì tính phi tuyến ở vùng đầu vào trung gian. Sự kết hợp này góp phần ổn định quá trình huấn luyện trong các mạng nhiều lớp, đặc biệt khi phương sai phần thưởng cao.

GeLU hiện là hàm kích hoạt mặc định trong nhiều kiến trúc hiện đại và đã được kiểm chứng rộng rãi trong thực nghiệm.

3.5.5. Bộ tối ưu tham số

AdamW được lựa chọn thay vì Adam truyền thống vì khắc phục được vấn đề regularization không đồng đều giữa các tham số - một hạn chế đã được chỉ ra bởi Loshchilov và Hutter (2019). Trong Adam, weight decay bị chia cho ước lượng moment bậc hai, khiến mức độ regularization phụ thuộc vào lịch sử gradient của từng tham số. AdamW tách riêng weight decay khỏi bước cập nhật gradient, đảm bảo regularization đồng đều và cải thiện khả năng tổng quát hóa. Đây là optimizer tiêu chuẩn trong các kiến trúc hiện đại và đã được kiểm chứng rộng rãi trong thực nghiệm.

Bảng 3-4. Bảng tham số của AdamW

Tham số	Ký hiệu	Giá trị	Ý nghĩa
Epsilon	ϵ	10^{-6}	Hằng số ổn định số học
Weight decay	λ	10^{-4}	Mức regularization nhẹ, đủ để hạn chế overfitting mà không cản trở khả năng khám phá chính sách mới của tác nhân

Các tham số của AdamW sử dụng trong nghiên cứu được thể hiện ở Bảng 3-4.

3.5.6. Tốc độ học giảm dần

Nghiên cứu sử dụng chiến lược giảm tuyến tính cho tốc độ học, trong đó learning rate giảm tỉ lệ thuận với tiến trình huấn luyện còn lại theo công thức:

$$\alpha(t) = \alpha_0 p(t)$$

Trong đó α_0 là tốc độ học ban đầu và $p(t) \in [0,1]$ là tỉ lệ tiến trình huấn luyện còn lại, bắt đầu từ 1 và giảm về 0 khi kết thúc. Ở giai đoạn đầu, tốc độ học cao cho phép tác nhân khám phá nhanh không gian chính sách; ở giai đoạn sau, tốc độ học giảm dần giúp ổn định chính sách đã học, tránh hiện tượng agent thay đổi chiến lược đột ngột khi đã hội tụ gần chính sách tối ưu. So với tốc độ học cố định, learning rate decay đã được chứng minh giúp cải thiện sự ổn định của quá trình huấn luyện trong các thuật toán policy gradient.

3.6. KẾT QUẢ THỰC NGHIỆM

Do nghiên cứu tiến hành huấn luyện nhiều bộ trích xuất đặc trưng khác nhau với các cấu hình tham số khác nhau, các mô hình được đặt tên theo quy ước gồm tên kiến trúc và độ dài episode huấn luyện. Ví dụ, LSTM-4320 là mô hình sử dụng bộ feature extractor LSTM với độ dài episode bằng 4320 bước thời gian, còn GRU-720 là mô hình sử dụng bộ feature extractor GRU với độ dài episode bằng 720 bước thời gian.

3.6.1. Quá trình huấn luyện

Tác nhân được huấn luyện trong tổng cộng 2.600.000 bước thời gian trên tập dữ liệu huấn luyện bằng thuật toán PPO, triển khai trên thư viện Stable-Baselines3. Để đánh giá mức độ hội tụ và tính ổn định của quá trình học, nghiên cứu theo dõi bốn chỉ số gồm reward mean, value loss, explained variance và clip fraction.


Reward mean phản ánh phần thưởng trung bình mà tác nhân đạt được trong quá trình huấn luyện. Khi chỉ số này tăng dần, có thể thấy tác nhân đang học được chính sách phù hợp hơn với hàm phần thưởng đã thiết kế.

Value loss thể hiện sai số giữa giá trị dự đoán và giá trị thực tế của mạng Critic, chỉ số này giảm dần cho thấy khả năng ước lượng giá trị trạng thái được cải thiện.

Explained variance dùng để đánh giá mức độ phù hợp giữa giá trị dự đoán của mạng Critic và giá trị thực. giá trị càng gần 1 thì mô hình dự đoán càng tốt, trong khi giá trị nhỏ hơn 0 cho thấy mô hình dự đoán kém.


Clip fraction biểu thị tỷ lệ các cập nhật bị giới hạn bởi cơ chế clipping trong PPO, qua đó phản ánh mức độ ổn định của quá trình tối ưu tham số.

Trong nghiên cứu này, hai mô hình đại diện gồm GRU-4320 và LSTM-4320 được lựa chọn để trình bày trong phần chính nhằm đảm bảo tính đại diện cho hai kiến trúc feature extractor khác nhau. Các mô hình còn lại được đưa vào PHỤ LỤC 1.



Hình 3-8. Biểu đồ của mạng GRU-4320

Kết quả huấn luyện của mô hình GRU-4320 được trình bày trong Hình 3-8. Quan sát các đường đặc trưng cho thấy reward mean có xu hướng tăng dần trong phần lớn quá trình học, dù xuất hiện một số dao động nhỏ ở giai đoạn giữa. Đồng thời, value loss giảm mạnh ở giai đoạn đầu và sau đó duy trì ở mức ổn định, trong khi explained variance nhanh chóng tiệm cận vùng giá trị tốt. Diễn biến của clip fraction cũng cho thấy xu hướng giảm dần về cuối quá trình huấn luyện. Nhìn chung, GRU-4320 thể hiện mức độ hội tụ tương đối tốt và quá trình học khá ổn định.



Hình 3-9. Biểu đồ của mạng LSTM-4320

Kết quả huấn luyện của mô hình LSTM-4320 được trình bày trong Hình 3-9. Tương tự GRU-4320, reward mean của mô hình này tăng dần theo thời gian, cho thấy tác nhân từng bước học được chính sách giao dịch phù hợp hơn. Value loss có xu hướng giảm, còn explained variance tiến gần ngưỡng lý tưởng, phản ánh khả năng ước lượng giá trị trạng thái ngày càng chính xác. Clip fraction biến động ở giai đoạn đầu và giảm dần về cuối, cho thấy quá trình cập nhật tham số dần ổn định. Những kết quả này cho thấy LSTM-4320 đạt mức hội tụ tương đối tốt trong quá trình huấn luyện.


Từ các biểu đồ trên có thể thấy GRU-4320 và LSTM-4320 đều cho diễn biến huấn luyện ổn định. Điều này gợi ý rằng các kiến trúc mạng nơ-ron tuần tự phù hợp với đặc trưng của dữ liệu trong nghiên cứu này.

3.6.2. Kết quả kiểm thử


Các chỉ số hiệu suất giao dịch được tính toán bằng thư viện VectorBT, một thư viện mã nguồn mở chuyên dụng cho việc phân tích hiệu suất danh mục đầu tư. Trong nghiên cứu này, chiến lược B&H được sử dụng làm baseline để so sánh. Lãi suất phi rủi ro được giả định ở mức 5,2%/năm, tương ứng với lãi suất tiền gửi tiết kiệm dành cho khách hàng cá nhân của Ngân hàng Vietcombank tại thời điểm nghiên cứu. Các chỉ số tỷ lệ Sharpe được annualize bằng cách nhân với $\sqrt{N}$, trong đó $N = 8760$ là số nến 1 giờ trong một năm.

Cách quy đổi này phản ánh đặc thù giao dịch liên tục 24/7 của thị trường tiền mã hóa.

Các biểu đồ dưới đây thể hiện sự so sánh giữa lợi nhuận tích lũy của tác nhân và chiến lược cơ sở của các mô hình đại diện. Các mô hình còn lại được trình bày trong PHỤ LỤC 2.



Hình 3-10. Biểu đồ lợi nhuận tích lũy của GRU-4320 so sánh với B&H



Hình 3-11. Biểu đồ lợi nhuận tích lũy của LSTM-4320 so sánh với B&H

Quan sát Hình 3-10 cho thấy mô hình GRU-4320 đạt mức lợi nhuận tích lũy dương và có xu hướng ổn định hơn về cuối giai đoạn kiểm thử, với mức lợi nhuận đạt 11,27%. Hình 3-11 cho thấy mô hình LSTM-4320 cho hiệu quả tốt nhất trong các mô hình khảo sát, với lợi nhuận tích lũy đạt 42,1% và diễn biến tương đối ổn định trong suốt quá trình kiểm thử.

Bảng 3-5. Kết quả kiểm thử của chiến lược cơ sở

Tên	CR(%)	Sharpe	MDD(%)
B&H	16.95	0.33	-50.08

Bảng 3-6. Kết quả kiểm thử của mô hình

Feature extractor	Độ dài episode	CR(%)	Sharpe	MDD(%)	Thời gian huấn luyện (giờ)
GRU	720	14.66	0.54	-6.25	3.36
	2160	19.86	0.98	-8.43	2.51
	4320	11.27	0.22	-17.97	3.6
LSTM	720	-18.46	-0.95	-36.37	3.29
	2160	-0.44	-0.20	-27.20	3.73
	4320	42.11	1.10	-12.25	3.62

Kết quả kiểm thử của chiến lược B&H và các mô hình được trình bày trong Bảng 3-5 và Bảng 3-6. Xét trên chiến lược cơ sở, B&H đạt CR ở mức 16,95%, tỷ lệ Sharpe bằng 0,33 và MDD là -50,08%. Mặc dù mức sinh lợi của B&H tương đối dương, mức suy giảm tối đa khá lớn cho thấy chiến lược này còn tiềm ẩn rủi ro đáng kể khi áp dụng trong thị trường có biến động mạnh.

Trong số các mô hình được khảo sát, LSTM-4320 là cấu hình cho kết quả tốt nhất. Mô hình này đạt CR 42,11%, tỷ lệ Sharpe 1,10 và MDD -12,25%, cho thấy khả năng tạo lợi nhuận cao đồng thời kiểm soát rủi ro tương đối tốt. So với chiến lược B&H, LSTM-4320 không chỉ cải thiện rõ rệt về mức sinh lợi mà còn giảm đáng kể mức sụt giảm tối đa, qua đó thể hiện hiệu quả vượt trội về cả hiệu suất và độ ổn định danh mục.

Ở nhóm mô hình GRU, cấu hình GRU-2160 cho kết quả tương đối cân bằng, với CR đạt 19,86%, tỷ lệ Sharpe bằng 0,98 và MDD ở mức -8,43%. Đây là mô hình có sự kết hợp tốt giữa khả năng sinh lợi và mức độ kiểm soát rủi ro. GRU-720 cũng cho kết quả dương, song hiệu quả thấp hơn GRU-2160; trong khi đó, GRU-4320 suy giảm rõ rệt về cả lợi nhuận và độ ổn định, cho thấy việc gia tăng độ dài episode không đồng nghĩa với việc cải thiện hiệu quả kiểm thử.

Đối với LSTM, kết quả có sự phân hóa mạnh theo độ dài episode. Hai cấu hình LSTM-720 và LSTM-2160 cho kết quả kém khả quan, thậm chí CR âm và MDD lớn, phản ánh khả năng khai thác dữ liệu chưa tốt ở các chuỗi ngắn hơn. Ngược lại, khi độ dài episode tăng lên 4320, mô hình LSTM thể hiện sự cải thiện rõ rệt và trở thành cấu hình tốt nhất trong toàn bộ các mô hình khảo sát. Điều này cho thấy LSTM có xu hướng phát huy hiệu quả hơn khi được cung cấp ngữ cảnh dài hơn trong quá trình học và kiểm thử.

Xét về thời gian huấn luyện, các mô hình trong tập thí nghiệm có xu hướng hội tụ ở mức tương đối nhanh, song thời gian huấn luyện ngắn hơn không đồng nghĩa với hiệu quả kiểm thử cao hơn. Trong số các cấu hình được khảo sát, LSTM-4320 và GRU-2160 đều cho thấy kết quả thực nghiệm tích cực, cho thấy hiệu suất giao dịch không chỉ phụ thuộc vào số giờ huấn luyện mà còn chịu tác động đáng kể bởi khả năng biểu diễn đặc trưng chuỗi của từng kiến trúc và mức độ phù hợp của độ dài episode đối với dữ liệu đầu vào. Từ đó, có thể nhận định rằng LSTM-4320 là mô hình thể hiện hiệu quả tổng thể tốt nhất trong tập thí nghiệm này, trong khi GRU-2160 là phương án đạt được sự cân bằng tương đối giữa lợi nhuận và rủi ro.

3.6.3. Thảo luận kết quả

Kết quả thực nghiệm cho thấy hiệu quả giao dịch của các mô hình phụ thuộc đáng kể vào cả kiến trúc feature extractor và độ dài episode. Trong số các cấu hình được khảo sát, LSTM-4320 là mô hình cho hiệu quả tổng thể tốt nhất, khi đồng thời đạt mức sinh lợi cao, tỷ lệ Sharpe lớn và mức sụt giảm tối đa tương đối thấp. Điều này cho thấy, với dữ liệu và bài toán đang xét, kiến trúc LSTM phát huy hiệu quả khi được cung cấp ngữ cảnh chuỗi dài hơn, qua đó khai thác tốt hơn các phụ thuộc theo thời gian trong biến động giá.

Bên cạnh đó, GRU-2160 cũng cho thấy kết quả tương đối cân bằng giữa lợi nhuận và rủi ro. So với các cấu hình còn lại, GRU có xu hướng ổn định hơn ở các episode ngắn và trung bình; tuy nhiên, hiệu quả cao nhất lại không xuất hiện ở episode dài nhất. Điều này gợi ý rằng việc gia tăng độ dài episode không phải lúc nào cũng dẫn đến cải thiện hiệu suất, mà còn phụ thuộc vào mức độ phù hợp giữa cấu trúc mô hình và đặc trưng của dữ liệu đầu vào.

Nhìn chung, các kết quả thực nghiệm khẳng định rằng khả năng biểu diễn phụ thuộc thời gian đóng vai trò quan trọng đối với hiệu quả của chiến lược giao dịch được đề xuất.

3.6.4. Hạn chế của đề tài

Mặc dù mô hình đã cho thấy một số kết quả khả quan, nghiên cứu vẫn còn tồn tại những hạn chế nhất định. Thứ nhất, dữ liệu đầu vào chỉ được giới hạn trong phạm vi tập dữ liệu và khung thời gian đã thu thập, nên chưa phản ánh đầy đủ toàn bộ trạng thái biến động của thị trường.

Thứ hai, các mô hình hiện mới được đánh giá chủ yếu dựa trên một nhóm chỉ số hiệu suất giao dịch cơ bản, trong khi chưa xem xét sâu hơn các yếu tố như độ ổn định theo từng giai đoạn thị trường, mức độ nhạy cảm với chi phí giao dịch, trượt giá và các điều kiện thanh khoản. Trong các nghiên cứu tiếp

theo, có thể mở rộng phân tích theo hướng này để đánh giá sát hơn hiệu quả thực tế của chiến lược.

Thứ ba, quá trình lựa chọn tham số vẫn còn phụ thuộc nhiều vào thử nghiệm thực nghiệm, nên chưa thể khẳng định đây là bộ siêu tham số tối ưu tuyệt đối cho từng mô hình. Ngoài ra, nghiên cứu mới dừng ở đánh giá hiệu quả kiểm thử, chưa tiến hành kiểm định độ bền của mô hình trên nhiều giai đoạn thị trường khác nhau.

3.6.5. Kết luận

Từ các kết quả thực nghiệm có thể kết luận rằng mô hình giao dịch sử dụng LSTM với độ dài episode bằng 4320 đạt hiệu quả tốt nhất trong số các cấu hình được khảo sát. Mô hình này không chỉ tạo ra mức sinh lợi cao hơn chiến lược cơ sở Buy and Hold mà còn kiểm soát rủi ro tốt hơn thông qua mức sụt giảm tối đa thấp hơn đáng kể. GRU-2160 cũng cho thấy hiệu quả tích cực và có thể được xem là một lựa chọn cân bằng giữa lợi nhuận và độ ổn định.

Kết quả thu được cho thấy hiệu quả của chiến lược giao dịch không chỉ phụ thuộc vào thuật toán học tăng cường, mà còn phụ thuộc mạnh vào khả năng biểu diễn chuỗi thời gian của kiến trúc feature extractor và mức độ phù hợp của độ dài episode huấn luyện. Do đó, việc lựa chọn kiến trúc mô hình và cấu hình huấn luyện phù hợp có vai trò quyết định đối với hiệu quả cuối cùng của hệ thống.

3.6.6. Hướng phát triển


Trong các nghiên cứu tiếp theo, có thể mở rộng mô hình theo một số hướng. Trước hết, cần đánh giá mô hình trên tập dữ liệu lớn hơn và trên nhiều giai đoạn thị trường khác nhau để kiểm tra tính ổn định và khả năng tổng quát hóa. Bên cạnh đó, có thể bổ sung thêm các chỉ số đánh giá như Sortino ratio, Calmar ratio hoặc các thước đo liên quan đến chi phí giao dịch để phản ánh đầy đủ hơn hiệu quả thực tế của chiến lược.

Ngoài ra, nghiên cứu có thể tiếp tục cải tiến kiến trúc feature extractor bằng cách thử nghiệm các mô hình lai hoặc các kiến trúc Transformer nhằm tăng khả năng nắm bắt phụ thuộc dài hạn trong dữ liệu. Việc tinh chỉnh siêu tham số bằng các phương pháp tối ưu tự động cũng là một hướng phát triển phù hợp để cải thiện hiệu quả của mô hình.


PHỤ LỤC

PHỤ LỤC 1. HÌNH ẢNH VỀ ĐỘ HỘI TỤ CỦA CÁC MÔ HÌNH	63
PHỤ LỤC 2. HÌNH ẢNH BIỂU ĐỒ SO SÁNH TÁC NHÂN VỚI CHIẾN LƯỢC CƠ SỞ	66


PHỤ LỤC 1. HÌNH ẢNH VỀ ĐỘ HỘI TỤ CỦA CÁC MÔ HÌNH




Hình PL 1. Biểu đồ của mạng GRU-720



Hình PL 2. Biểu đồ của mạng GRU-2160



Hình PL 3. Biểu đồ của mạng LSTM-720




Hình PL 4. Biểu đồ của mạng LSTM-2160


Hình PL 1 và Hình PL 2 biểu diễn lần lượt quá trình hội tụ của mạng GRU-720 và GRU-2160. Hình PL 3 và Hình PL 4 biểu diễn quá trình hội tụ của

mạng LSTM-720 và LSTM-2160. Quá trình hội tụ của các mạng này diễn ra ổn định.


PHỤ LỤC 2. HÌNH ẢNH BIỂU ĐỒ SO SÁNH TÁC NHÂN VỚI CHIẾN LƯỢC CƠ SỞ




Hình PL 5. Biểu đồ lợi nhuận tích lũy của GRU-720 so sánh với B&H



Hình PL 6. Biểu đồ lợi nhuận tích lũy của GRU-2160 so sánh với B&H



Hình PL 7. Biểu đồ lợi nhuận tích lũy của LSTM-720 so sánh với B&H



Hình PL 8. Biểu đồ lợi nhuận tích lũy của LSTM-2160 so sánh với B&H

Quan sát Hình PL 5, Hình PL 6 cho thấy hai mô hình GRU-720 và GRU-2160 đều nhận diện được tín hiệu trong dữ liệu và dần hội tụ về một chiến lược giao dịch có lợi nhuận. Hình PL 7 cho thấy mô hình LSTM-720 đạt hiệu quả tốt ở giai đoạn đầu của thị trường nhưng suy giảm về sau, dẫn đến kết quả thua lỗ. Trong khi đó, Hình PL 8 cho thấy LSTM-2160 có hiệu suất tương đối tốt ở giai đoạn giữa, song hiệu quả giảm dần vào cuối giai đoạn kiểm thử.

TÀI LIỆU THAM KHẢO

- Arulkumaran, K., Deisenroth, M. P., Brundage, M., & Bharath, A. A. (2017). A Brief Survey of Deep Reinforcement Learning. *IEEE Signal Processing Magazine*, 34(6), 26–38. <https://doi.org/10.1109/MSP.2017.2743240>
- Ba, J. L., Kiros, J. R., & Hinton, G. E. (2016, Tháng Bảy 21). *Layer Normalization*. arXiv. <https://doi.org/10.48550/arXiv.1607.06450>
- Briola, A., Turiel, J., Marcaccioli, R., Caudean, A., & Aste, T. (2023, Tháng Tám 19). *Deep Reinforcement Learning for Active High Frequency Trading*. arXiv. <https://doi.org/10.48550/arXiv.2101.07107>
- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014, Tháng Chạp 11). *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*. arXiv. <https://doi.org/10.48550/arXiv.1412.3555>
- Filos, A. (2019, Tháng Chín 12). *Reinforcement Learning for Portfolio Management*. arXiv. <https://doi.org/10.48550/arXiv.1909.09571>
- Hendrycks, D., & Gimpel, K. (2023, Tháng Sáu 6). *Gaussian Error Linear Units (GELUs)*. arXiv. <https://doi.org/10.48550/arXiv.1606.08415>
- Huang, C. Y. (2018, Tháng Bảy 8). *Financial Trading as a Game: A Deep Reinforcement Learning Approach*. arXiv. <https://doi.org/10.48550/arXiv.1807.02787>
- Jay, P., Kalariya, V., Parmar, P., Tanwar, S., Kumar, N., & Alazab, M. (2020). Stochastic Neural Networks for Cryptocurrency Price Prediction. *IEEE Access*, 8, 82804–82818. <https://doi.org/10.1109/ACCESS.2020.2990659>
- Jiang, Z., Xu, D., & Liang, J. (2017, Tháng Bảy 16). *A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem*. arXiv. <https://doi.org/10.48550/arXiv.1706.10059>
- Kabbani, T., & Duman, E. (2022). Deep Reinforcement Learning Approach for Trading Automation in The Stock Market. *IEEE Access*, 10, 93564–93574. <https://doi.org/10.1109/ACCESS.2022.3203697>
- Li, Y. (2018a, Tháng Mười 15). *Deep Reinforcement Learning*. arXiv. <https://doi.org/10.48550/arXiv.1810.06339>
- Li, Y. (2018b, Tháng Mười-Một 26). *Deep Reinforcement Learning: An Overview*. arXiv. <https://doi.org/10.48550/arXiv.1701.07274>
- Li, Z. (2024). TLACP: A Hybrid Deep Learning Model for Stock Market Prediction. *Proceedings of the 2024 3rd International Conference on Cyber*

- Security, Artificial Intelligence and Digital Economy*, 469–479. Nanjing China: ACM. <https://doi.org/10.1145/3672919.3673004>
- Loshchilov, I., & Hutter, F. (2019, Tháng Giêng 4). *Decoupled Weight Decay Regularization*. arXiv. <https://doi.org/10.48550/arXiv.1711.05101>
- Millea, A. (2021). Deep Reinforcement Learning for Trading—A Critical Survey. *Data*, 6(11), 119. <https://doi.org/10.3390/data6110119>
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., ... Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533. <https://doi.org/10.1038/nature14236>
- Rundo, F., Trenta, F., Di Stallo, A. L., & Battiato, S. (2019). Machine Learning for Quantitative Finance Applications: A Survey. *Applied Sciences*, 9(24), 5574. <https://doi.org/10.3390/app9245574>
- Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2018, Tháng Mười 20). *High-Dimensional Continuous Control Using Generalized Advantage Estimation*. arXiv. <https://doi.org/10.48550/arXiv.1506.02438>
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017, Tháng Tám 28). *Proximal Policy Optimization Algorithms*. arXiv. <https://doi.org/10.48550/arXiv.1707.06347>
- Sezer, O. B., Gudelek, M. U., & Ozbayoglu, A. M. (2019, Tháng Mười-Một 29). *Financial Time Series Forecasting with Deep Learning: A Systematic Literature Review: 2005-2019*. arXiv. <https://doi.org/10.48550/arXiv.1911.13288>
- Shah, J., Vaidya, D., & Shah, M. (2022). A comprehensive review on multiple hybrid deep learning approaches for stock prediction. *Intelligent Systems with Applications*, 16, 200111. <https://doi.org/10.1016/j.iswa.2022.200111>
- Sutton, R. S., & Barto, A. (2014). *Reinforcement learning: An introduction* (Nachdruck). Cambridge, Massachusetts: The MIT Press.
- TA-Lib. (2026). *TA-Lib: Technical Analysis Library*. Truy vấn từ <https://ta-lib.org/>
- Théate, T., & Ernst, D. (2021). An Application of Deep Reinforcement Learning to Algorithmic Trading. *Expert Systems with Applications*, 173, 114632. <https://doi.org/10.1016/j.eswa.2021.114632>
- Towers, M., Kwiatkowski, A., Terry, J., Balis, J. U., Cola, G. D., Deleu, T., ... Younis, O. G. (2025, Tháng Mười-Một 2). *Gymnasium: A Standard Interface*

- for Reinforcement Learning Environments.* arXiv.
<https://doi.org/10.48550/arXiv.2407.17032>
- Trần, T. K. T., Võ, M. H., Lê, L. N. T., & Vo, V. T. X. H. (2023). Thuật toán học tăng cường cải tiến dựa trên xu hướng dữ liệu để ra quyết định mua bán trên thị trường tiền điện tử. *Can Tho University Journal of Science*, 59(3), 224–235. <https://doi.org/10.22144/ctu.jvn.2023.151>
- Wang, H., Huang, W., & Wang, S. (2021, Tháng Ba 31). *Forecasting open-high-low-close data contained in candlestick chart.* arXiv.
<https://doi.org/10.48550/arXiv.2104.00581>
- Yang, Z., Yang, D., Dyer, C., He, X., Smola, A., & Hovy, E. (2016). Hierarchical Attention Networks for Document Classification. *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 1480–1489. San Diego, California: Association for Computational Linguistics.
<https://doi.org/10.18653/v1/N16-1174>
- Zhang, Z., Zohren, S., & Roberts, S. (2019, Tháng Mười-Một 22). *Deep Reinforcement Learning for Trading.* arXiv.
<https://doi.org/10.48550/arXiv.1911.10107>